

Министерство образования и науки Российской Федерации
ТАМБОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Н.В. Майстренко, А.В. Майстренко

ОСНОВЫ ТЕОРИИ ИНФОРМАЦИИ И КРИПТОГРАФИИ

Учебное пособие

Тамбов – 2018

УДК
ББК

Рецензенты:

Зав. кафедрой «Математическое моделирование и информационные технологии» Государственного образовательного учреждения высшего образования Тамбовского государственного университета им. Г.Р. Державина, д. т. н., профессор *Арзамасцев Александр Анатольевич*

Декан факультета «Естественнонаучный и гуманитарный» Государственного образовательного учреждения высшего образования «Тамбовский государственный технический университет», д. т. н., доцент *Толстяков Роман Рашидович*

Майстренко А.В., Майстренко Н.В.

Рассмотрены различные аспекты количественной меры информации, информационные характеристики источников информации и каналов связи, методы и средства кодирования информации. Учебное пособие предназначено для обучающихся по направлению 09.03.01 – Информатика и вычислительная техника.

ВВЕДЕНИЕ

Теория информации – наука, имеющая точную дату своего "рождения". Связана она, прежде всего с опубликованием работы Клода Шеннона «Математическая теория связи. Работы по теории информации и кибернетике» в 1948 году. Шенноном была определена количественная мера информации и показано, что информационное обеспечение случайного процесса всецело определяется его вероятностными характеристиками.

Сегодня из чисто теоретической науки теория информации трансформировалась в прикладную науку. В настоящее время невозможно представить наш повседневный образ жизни без высокоскоростных модемов, телефонных каналов, глобальной сети Интернет, лазерных компакт-дисков, флэшек и съемных винчестеров большой емкости для персональных компьютеров, мобильных сотовых телефонов, кредитных карт и много другого, что связано с передачей или хранением информации. Характерно и то, что источники информации являются дискретными, информация кодируется, хранится и декодируется в цифровой форме.

Кроме того, необходимо отметить, что большие объемы информации не передаются по каналам связи в первозданном виде, а должны эффективно кодироваться (сжиматься), а иногда и шифроваться.

Дисциплина «Основы теории информации и криптографии» для обучающихся по направлению «Информатика и вычислительная техника» прежде всего ориентирована на изучение методов и алгоритмов эффективного.

Настоящее пособие является введением в общий курс теории информации. В пособии рассмотрены различные аспекты количественной меры информации объектов с дискретным множеством состояний, информационные характеристики дискретных источников информации и каналов связи, методы и средства кодирования информации.

1. Основные понятия. Система передачи информации

Еще с 50-х годов прошлого века предпринимались попытки использовать понятие "информация" для описания и объяснения разнообразных процессов и явлений.

Некоторые фундаментальные учебники дают определение информации следующего плана:

Информация - это совокупность сведений, подлежащих хранению, передаче, обработке и использованию в человеческой деятельности.

Стоит отметить, что данное определение не совсем бесполезно, хотя в нем определяемое понятие (*информация*) подменяется другим – *совокупность сведений*, которое также нуждается в определении.

Сам по себе термин «Информация» можно отнести в раздел наиболее часто употребляемых. Не смотря на то, что данный термин широко применяется в биологии, лингвистике, психологии и некоторых других науках, в различных областях знаний в него вкладывают разный смысл.

Большой интерес к разнообразным информационным процессам повлек за собой многочисленные толкования определений понятия «информация». То же касается и определений количества информации, которых существует довольно много. Наиболее адекватным постановке задачи считается *шенноновское определение информации как меры неопределенности*. Как следствие, основной целью передачи информации является *снятие* данной *неопределенности*.

Все подходы к определению количества информации условно делят на пять видов:

- 1) энтропийный;
- 2) алгоритмический;
- 3) комбинаторный;
- 4) семантический;
- 5) прагматический.

Энтропийный, алгоритмический и комбинаторный подходы могут дать количественное установление сложности объекта или явления, которое подвергалось наблюдению. Семантический подход позволяет описать содержательную составляющую и новизну передаваемого сообщения именно для конкретного получателя (пользователя) сообщения. Полезность уже полученного сообщения для конечного пользователя позволяет оценить прагматический подход к измерению информации.

Термин «информация» произошел от латинского слова «informatio», что переводится как «разъяснение», и, в сущности, предполагает существование диалога между отправителем и получателем информации. Как следствие, информационное взаимодействие можно представить пятикомпонентной (пятимерной векторной) величиной, состоящей из следующих компонент:

- 1) физической;
- 2) сигнальной;
- 3) лингвистической;
- 4) семантической;
- 5) прагматической.

Необходимо отметить, что подобное разбиение информационного взаимодействия носит довольно условный характер и возможно частичное пересечение в этом разбиении. Так, отдельные составляющие передаваемого сообщения можно отнести к физической или сигнальной, сигнальной или лингвистической компонентам.

Если рассматривать процесс передачи информации на примере устной речи, то можно, прежде всего, отметить многокомпонентность данного процесса. Физической компонентой в данном случае является необходимость наличия физической среды для распространения акустических колебаний (воздуха), источника акустического сигнала (голосовых связок человека) и приемника колебаний (уха). Роль второй, сигнальной компоненты выполня-

ют акустические колебания, амплитудно и частотно модулированные. Третья, синтаксическая, компонента отображается в необходимости знания собеседниками хотя бы одного общего языка. Семантическая компонента – в передаваемом сообщении необходимо присутствие содержательного описания объекта или явления, которое до этого было неизвестно получателю информации. И, наконец, для эффективного процесса приема/передачи сообщения необходимо желание и мотивация – прагматическая компонента.

Для того чтобы информацию можно было обрабатывать с использованием технических средств, ее чаще всего необходимо представлять в некоем формализованном виде. Информацию в таком виде принято называть *данными*.

Обычно выделяют этапы обращения информации:

- 1) восприятие информации;
- 2) подготовка информации;
- 3) передача и хранение информации;
- 4) обработка информации;
- 5) отображение информации;
- 6) воздействие информации.

1.1. Система передачи информации

Модель системы передачи (и хранения) информации приведена на рис.

1.1.




Рис. 1.1. Система передачи информации

Опишем данную модель.

1. В качестве *источника информации или сообщения* можно представить физический объект, систему или явление, которые формируют передаваемое сообщение. При этом сообщение отображает изменение или значение некой физической величины, которое отражает состояние какого-либо объекта (системы или явления). Первичные сообщения – это, как правило, изображения, музыка, речь, измерения параметров окружающей среды и т.д., представляющие собой функции времени неэлектрической природы. Преобразование первичных сообщений в электрический сигнал необходимо для их передачи по каналу связи. Изменения во времени $\lambda(t)$ этого сигнала отображает передаваемое сообщение.

Следует отметить, что большинство передаваемых сообщений не являются сигналами – текстовые или другие файлы, массивы чисел и т.д. Такие сообщения представляют в виде векторов $\mathbf{A}$.

2. *Кодер источника.*

Исходные сообщения в виде изображений, речи, музыки и т.п. предназначены прежде всего для восприятия органами чувств приемника сообщения (человека). Такие сообщения ($\lambda(t)$ или A) крайне неэффективно передавать в первоизданном виде по каналам связи, поэтому они чаще всего кодируются. Зачастую до непосредственно процедуры кодирования исходное сообщение необходимо дискретизировать, т.е. преобразовать непрерывное сообщение $\lambda(t)$ в последовательность неких элементарных дискретных сообщений $\{\lambda_i\}$.

Кодирование в общем случае – это процесс преобразования алфавита сообщения $A\{\lambda_i\}$, ($i = 1, 2 \dots K$) в алфавит кодовых символов $\mathcal{R}\{x_j\}$, ($j = 1, 2 \dots N$), которые выбираются некоторым образом. При этом чаще всего (хотя и необязательно) алфавит кодовых символов $\dim \mathcal{R}\{x_j\}$ имеет меньший или намного меньший объем, чем алфавит источника $\dim A\{\lambda_i\}$.

К целям процесса кодирования сообщений можно отнести увеличение скорости передаваемой информации, сжатие данных (сокращение объема исходного сообщения, данных), повышение достоверности передачи данных, предоставление секретности при передаче данных и др.

Кодировка источника будет означать уменьшение объема (сжатия) информации для того, чтобы увеличить скорость ее передачи или уменьшить частотную полосу, необходимую для передачи данных.

Кодирование источника при этом иногда называют экономичным или эффективным кодированием, или также сжатием данных. Под эффективностью понимается степень сокращения объема данных, предоставляемых кодированием.

Следует отметить, что если сжатие заключается в том, что сжатые данные могут быть использованы для точного восстановления исходной информации, кодирование называется неразрушающим. Неразрушающего кодирования используется в передачи (или хранения) текстовой информации, численных данных, файлов и т. д., то есть, где даже малейшие различия между исходными и восстановленными данными недопустимы.

В абсолютно точной передаче информации от источника к приемнику зачастую нет необходимости. В каналах связи практически всегда имеются помехи, абсолютно точная передача невозможна в принципе.

Тогда можно применять методы разрушающего (с потерями) сжатия, которые могут обеспечить восстановление исходного сообщения из сжатого сообщения с некоторой степенью приближения. Обычно методы сжатия данных с потерями более эффективны, чем неразрушающие методы (без потерь).

По передаваемому сообщению $\lambda(t)$ или A на выходе *кодера источника* таким образом вырабатывается последовательность кодовых символов X , которая в свою очередь носит название *информационная последовательность* и должна иметь возможность точно (или приближенно) быть восстановленной в исходное сообщение и иметь как можно меньший размер

3. *Кодер канала.* В каналах связи часто бывают помехи, вследствие чего при передаче информации по такому каналу в принятых данных можно фиксировать ошибки. В случае возникновения редких ошибок или имеющих небольшую величину, информация используется получателем, иначе – полученная информация непригодна для дальнейшего использования.

Для оптимизации количества ошибок, которые возникают при передаче сообщения по каналу с помехами применяют *помехоустойчивое кодирование*, называемое также кодированием в канале.

Не смотря на наличие большого разнообразия методов кодирования информации в канале, общий их принцип основан на следующем: в передаваемые сообщения заносится некоторая специально подобранная избыточность (лишние избыточные символы), которая позволяет при приеме сообщения (в декодере канала) обнаружить и исправить возникающие ошибки.

Таким образом, в кодере источника при кодировании естественная избыточность, которая имеет место в исходном сообщении, устраняется, тогда как в кодере канала в передаваемое сообщение сознательно вносится специальная избыточность. Последовательность кодовых символов , форми-

руемая в результате работы кодера канала на выходе, называется *кодовой последовательностью*.

Следует отметить, что процедуры сжатия данных и помехоустойчивого кодирования не являются обязательными в системе передачи информации. Однако отсутствие этих процедур зачастую приводит к значительным изъясам в помехоустойчивости системы, снижению скорости передачи данных, а вследствие и ухудшению качества передачи информации.

4. *Модулятор*. Основная функция модулятора заключается в согласовании сообщения источника или кодовых последовательностей, которые вырабатываются кодером со свойствами конкретного канала связи, а также предоставление возможностей одновременной передачи по общему каналу связи большого числа сообщений.

На самом деле большая часть передаваемых сообщений (непрерывных и дискретных Λ) и результаты кодирования таких сообщений (кодовые последовательности X и Y) являются низкочастотными сигналами с относительно широкой полосой ($\Delta F \leq 1 \text{ МГц}$, $\Delta F \sim f_0$). Тогда как передача информации при помощи электромагнитных колебаний эффективна для довольно высокочастотных сигналов ($f_0 \geq 1...1000 \text{ МГц}$ и выше) с относительно узкополосными спектрами ($\Delta F \ll f_0$).

Основная цель модулятора – преобразование сообщения источника $\lambda(t)$ или Λ (или кодовых последовательностей X и Y , соответственно) в такие сигналы $S(t, \lambda(t))$, $S(t, Y(\lambda(t)))$ путем наложения сообщения на сигналы, свойства которых могли бы обеспечить им возможность передачи по существующим каналам связи.

Данное преобразование также должно обеспечить независимую передачу сообщения от всех разнообразных источников информации ко всем получателям информации в общем используемом канале передачи информации.

Существующие на сегодняшний момент методы модуляции сигналов обладают различной эффективностью и позволяют обеспечить передачу информации с различным уровнем качества передачи. Самыми простыми и распространенными методами являются амплитудная модуляция, частотная модуляция и фазовая модуляция.

5. *Канал связи.* В качестве каналов передачи могут использоваться воздух, проводные каналы, волоконно-оптические каналы, акустические каналы и др. в зависимости от вида конкретной системы передачи информации.

Вне зависимости от выбранного канала передачи информации, сигнал $S(t, Y(\lambda(t)))$ вследствие прохождения по каналу может подвергаться ослаблению, получать временную задержку некоторой величины, зашумляться. Принимаемое приемником колебание $U(t)$ в этом случае имеет вид

$$U(t) = \varepsilon S(t - \tau, Y(\lambda(t))) + n(t), \quad (1.1)$$

где ε – затухание, τ – временное запаздывание, $n(t)$ – шумы в канале связи.

Приемник. Основным назначением приемника является воспроизведение с максимальной точностью по принятому колебанию на своём выходе переданного сообщения $\lambda(t)$ или Λ . При этом существует вероятность того, что принятое (воспроизведенное) сообщение будет отличаться от посланного из-за наличия помех в канале связи.

Назовём оценкой (в данном случае имеется в виду оценка сообщения) принятое сообщение и обозначим его $\lambda^*(t)$ или Λ^* . В общем случае процесс воспроизведения *оценки сообщения по принятому колебанию* $U(t)$ может включать несколько этапов.

6. *Демодулятор.* Для того чтобы воспроизвести оценку сообщения $\lambda^*(t)$ или Λ^* , приемник системы получает в первую очередь оценку кодовой последовательности $Y^*(\lambda(t))$ – принятую последовательность r . Эта оценка мо-

жет быть получена по принятому колебанию $U(t)$, обязательно учитывая особенности использованных при передаче сообщения видов сигналов и способе модуляции. Данная процедура носит название демодуляции (прием сигнала, детектирование). Следует понимать, что демодуляция должна быть выполнена с минимальным отличием принятой последовательности r от переданной кодовой последовательности Y .

В своей постановке и по способам решения задача демодуляции принятого колебания $U(t)$ в основном совпадает с различными вариантами задачи оптимального приема сигнала на фоне помех (оптимальное обнаружение, оптимальное различение двух или нескольких сигналов и т.д.).

7. *Декодер канала.* Принятая последовательность r как правило отличается от переданного кодового сообщения Y и может содержать ошибки. Количество ошибок зависит от многих факторов: уровень помех в канале связи, скорость передачи, способ модуляции и демодуляции. Задачей декодера в данном случае является обнаружение и исправление (по возможности) найденных ошибок – декодирование канала. Результатом декодирования r является оценка информационной последовательности X^* .

Выбор помехоустойчивого кода, способа кодирования, а также метода декодирования организуется таким образом, чтобы на выходе декодера канала оставалось бы наименьшее количество неисправленных ошибок.

В настоящее время трудно представить рассмотрение системы передачи информации без рассмотрения вопросов помехоустойчивого кодирования/декодирования, т.к. это позволяет в значительной мере повысить качество передачи информации. В случае особых повышенных требований к достоверности принимаемой информации (дистанционные системы управления, компьютерные сети передачи данных и т.д.), передача данных без применения помехоустойчивого кодирования невозможна.

8. *Декодер источника.*

Кодирование для более компактного или удобного представления информации источника ($\lambda(t)$, A) приводит к необходимости восстановления информации к исходному виду после приема. Декодирование источника – это процедура восстановления A^* по X^* . В случае применения на этапе кодирования методов разрушающего кодирования A^* может довольно значительно отличаться от A .

В зависимости от примененных методов кодирования декодирование источника может быть либо просто обратной операцией кодирования (неразрушающее кодирование/декодирование), либо восстанавливать приближенное значение A^* , в большей или меньшей степени отличающееся от A (разрушающее кодирование/декодирование).

Необходимо отметить, что в последнее время экономное кодирование занимает все более заметное место в системах передачи информации, поскольку, вместе с помехоустойчивым кодированием, это оказалось самым эффективным способом увеличения скорости и качества ее передачи.

В данном пособии мы уделим неразрушающим методам сжатия (сжатие без потерь) особое внимание. На эти же методы будут ориентированы и большинство лабораторных работ, выполняемых в рамках курса «Основы теории информации и криптографии». Методы же сжатия с потерями (разрушающее кодирование) будут подробно рассмотрены в рамках курсов «Мультимедийные технологии» и «Компьютерная графика», т.к. чаще всего данные методы применяются для кодирования больших объемов информации к которым относятся компьютерная графика, компьютерный звук и видеоданные.

2. Источники сообщений. Дискретизация. Квантование

Обычно под источником информации или сообщения подразумевается физический объект или система, которые формируют передаваемое сообщение. При этом само сообщение представляет собой непосредственно значе-

ние или изменение физической величины, которая отражает состояние объекта.

Первичные сообщения, как правило, представляют собой функции времени – $\lambda(t)$ или других аргументов – $\lambda(x, y, z)$ неэлектрической природы (акустическое давление, температура, распределение яркости на некоторой плоскости и т.п.) и несут смысловую нагрузку в виде речи, музыки, изображений, измерений каких-либо параметров окружающей среды и т.д.

Для их передачи по каналам связи сообщения необходимо преобразовать в электрические сигналы, изменения которых во времени $\lambda(t)$ будут отображать передаваемую информацию. Такие сообщения называются непрерывными, или аналоговыми, сообщениями (сигналами), и для них выполняются условия

$$\lambda \in (\lambda_{min}, \lambda_{max}), t \in (0, t), \quad (2.1)$$

то есть значение функции и значение аргумента для таких сообщений будут непрерывны либо определены для любого значения непрерывного интервала как по λ , так и по t (рис. 2.1,а,б).

Существует достаточное количество сообщений, которые носят дискретный характер. Это и команды исполнительным устройствам, и телеграфные сообщения, и даже текстовая информация и др. В данном случае алфавит сообщения $A(\lambda_i)$ представляет собой конечное счетное множество

$$\lambda_i = \lambda_1, \lambda_2, \dots, \lambda_k, i = 1, K \quad (2.2)$$

(сообщения, дискретные или квантованные по уровню, рис. 2.1,в), либо сами сигналы передаются лишь в дискретные моменты времени

$$t = t_1, t_2, \dots, t_m, i = 1, M \quad (2.3)$$

(дискретные по времени сообщения, рис. 2.1,г), либо и то и другое (дискретные по времени и по уровню сигналы, или, как их иначе называют, цифровые сигналы, или сообщения, рис. 2.1,д, е).

Большая часть передаваемых сообщений, в особенности в последнее время, вообще не является сигналами по своей природе – это могут быть пакеты данных, цифровые фотографии, результаты измерений различных па-

раметров, текстовые, графические или иные файлы и т.д. Такие сообщения обычно представляют либо в виде массивов чисел, в виде некоторых векторов λ .




Рис.2.1 Виды сигналов

Не сложно заметить, что все многообразие форм сообщений (или временных сигналов их отображающих), которое необходимо передать, можно классифицировать на несколько существенно отличающиеся виды:

- непрерывные по времени (аналоговые) сообщения (сигналы);
- дискретные по времени (дискретизованные) сообщения;
- дискретные по уровню (квантованные) сообщения.

Но даже такие на первый взгляд абсолютно разные сигналы, как непрерывные и дискретизованные (рис. 2.1), связаны функциональными зависимостями, которые устанавливаются теоремой Котельникова-Найквиста (теоремой дискретизации).

2.1. Теорема дискретизации

Можно бесконечно долго спорить о том, кому принадлежит пальма первенства в установлении связи между непрерывными и дискретными сигналами – Владимиру Ивановичу Котельникову, российскому ученому в области радиофизики или американскому ученому Гарри Найквисту (*Harry Nyquist*), но единственно непреложным установленным фактом является то, что на так называемой теореме отсчетов основана вся современная радиотехника.

Теорема Котельникова-Найквиста. Эта теорема позволяет установить соотношение *между непрерывными сигналами*, какими являются большинство реальных информационных сигналов – речь, музыка, электрические сигналы, соответствующие телевизионным изображениям, сигналы в цепях различных радиотехнических систем и т.п., *и значениями этих сигналов лишь в отдельные моменты времени – так называемыми отсчетами*. На использовании этой связи строится вся современная цифровая радиотехника – цифровые методы передачи и хранения звуковых и телевизионных сигналов, цифровые системы телефонной и сотовой связи, системы цифрового спутникового телевидения и т.д.

Теорема дискретизации, или, как ее еще называют, теорема Котельникова, теорема Уитекера, формулируется следующим образом: *непрерывная функция $X(t)$ с ограниченным спектром, то есть не имеющая в своем спектре*

$$F\{X(t)\} = \int_{-\infty}^{\infty} X(t) \cdot e^{-j2\pi ft} dt \quad (2.4)$$

составляющих с частотами, лежащими за пределами полосы $f \in (-F_m, F_m)$, полностью определяется последовательностью своих отсчетов в дискретные моменты времени $X(t_i)$, следующих с шагом $\Delta t < 1/F_m$.

Доказательство сформулированной теоремы основывается на однозначном соответствии между сигналами и соответствующими им спектрами. Иными словами, если сигналы одинаковы, то и соответствующие им спектры также одинаковы. И, наоборот, если спектры двух сигналов одинаковы, то и соответствующие сигналы также одинаковы.

По сути, теорема о выборках утверждает, что для точной дискретизации ее частота должна быть не менее чем в два раза выше наибольшей частоты гармоники, входящей в дискретизируемую величину¹

Примером использования этой теоремы являются лазерные компакт-диски, звуковая информация на которых хранится в цифровой форме. Чем выше будет частота дискретизации, тем точнее будут воспроизводиться звуки и тем меньше их можно будет записать на один диск, но ухо обычного человека способно различать звуки с частотой до 20КГц, поэтому точно записывать звуки с большей частотой бессмысленно. Согласно теореме о выборках частоту дискретизации нужно выбрать не меньшей 40КГц (в промышленном стандарте на компакт-диске используется частота 44.1КГц).

2.2. Квантование сообщений.

Передачу практически любых сообщений $\lambda(t)$ ($\{\lambda(x,y)\}$) можно свести к передаче их отсчетов, или чисел $\lambda_i = \lambda(i \Delta t)$, следующих друг за другом с интервалом дискретности $\Delta t \leq 1/2F_m$ ($\Delta x \leq 1/2f_x, \Delta y \leq 1/2f_y$). Тем самым непрерывное (бесконечное) множество возможных значений сообщения $\lambda(t)$ заменяется *конечным* числом его дискретных значений $\{\lambda(i \Delta t)\}$. Однако сами эти числа имеют непрерывную шкалу уровней (значений), то есть принадле-

жат опять же континуальному множеству. Для *абсолютно точного* представления таких чисел, к примеру, в десятичной (или двоичной) форме, необходимо теоретически *бесконечное* число разрядов. Вместе с тем *на практике* нет необходимости в *абсолютно точном* представлении значений λ_i , как и любых чисел вообще.

Во-первых, сами источники сообщений обладают ограниченным динамическим диапазоном и вырабатывают исходные сообщения с определенным уровнем искажений и ошибок. Этот уровень может быть большим или меньшим, но абсолютной точности воспроизведения достичь невозможно.

Во-вторых, передача сообщений по каналам связи всегда производится в присутствии различного рода помех. Поэтому принятое (воспроизведенное) сообщение (оценка сообщения $\lambda^*(t)$ или Λ^*) всегда в определенной степени отличается от переданного, то есть на практике *невозможна абсолютно точная передача* сообщений при наличии помех в канале связи.

Наконец, сообщения передаются для их восприятия и использования получателем. Получатели же информации – органы чувств человека, исполнительные механизмы и т.д. – также обладают конечной разрешающей способностью, то есть не замечают незначительной разницы между *абсолютно точным* и *приближенным* значениями воспроизводимого сообщения. Порог чувствительности к искажениям также может быть различным, но он всегда есть.

С учетом этих замечаний процедуру дискретизации сообщений можно продолжить, а именно подвергнуть отсчеты λ_i квантованию.

Процесс квантования состоит в замене непрерывного множества значений отсчетов $\lambda_i \in (\lambda_{\min}, \lambda_{\max})$ дискретным множеством $\{\lambda_{(1)}, \dots, \lambda_{(m)}\}$ из алфавита $A\{\lambda_i\}$. Тем самым точные значения чисел λ_i заменяются их приближенными (округленными до ближайшего разрешенного уровня) значениями. Интервал между соседними разрешенными уровнями λ_i , или уровнями квантования, $\Delta = \lambda_{(i+1)} - \lambda_{(i)}$ называется шагом квантования.

Различают равномерное и неравномерное квантование. В большинстве случаев применяется и далее подробно рассматривается равномерное квантование (рис. 2.2), при котором шаг квантования постоянный: $\Delta = \lambda_i - \lambda_{i-1} = \text{const}$; однако иногда определенное преимущество дает неравномерное квантование, при котором шаг квантования Δ_i разный для различных λ_i (рис. 2.3).




Рис. 2.2




Рис. 2.3

Квантование приводит к искажению сообщений. Если квантованное сообщение, полученное в результате квантования отсчета $\lambda_i = \lambda(i\Delta t)$, обозначить как λ_{iq} , то

$$\lambda_{iq} = \lambda_i + \xi_i, \quad (2.5)$$

где ξ_i – разность между квантованным сообщением (ближайшим разрешенным уровнем) λ_{iq} и истинным значением элементарного сообщения λ_i , называемая ошибкой квантования, или шумом квантования. Шум квантования оказывает на процесс передачи информации по существу такое же влияние, как и помехи в канале связи. Помехи, так же как и квантование, приво-

дят к тому, что оценки λ_i^* , получаемые на приемной стороне системы связи, отличаются на некоторую величину от истинного значения λ_i .

Относительно требуемой точности передачи отсчетов сообщений можно высказать те же соображения, что и для ошибок временной дискретизации: шумы квантования или искажения, обусловленные квантованием, не имеют существенного значения, если эти искажения меньше ошибок, обусловленных помехами и допустимых техническими условиями.

Так, например, при передаче речи и музыки искажения практически не заметны, если все отсчеты случайным образом изменить на 0,1...1%, при передаче изображений – на 1% и т.д. Даже профессиональный эксперт не может заметить искажений в музыкальном произведении, если квантование производится с точностью лучше 0,001% (число уровней квантования $N > 100000$, точность представления отсчетов – 16...17 двоичных разрядов).

Показано, что передачу практически *любых* сообщений $\lambda(t)$ ($\{\lambda(x,y)\}$) с *любой наперед заданной точностью* можно свести к передаче *целых чисел* $\lambda_{iq} = \lambda_q(i \Delta t)$, следующих друг за другом с интервалом дискретности $\Delta t \leq 1/2F_m$ ($\Delta x \leq 1/2f_x \max$, $\Delta y \leq 1/2f_y \max$). Тем самым непрерывное (*бесконечное*) множество возможных значений сообщения $\lambda(t)$ ($\{\lambda(x,y)\}$) заменяется *конечным* множеством целых чисел из алфавита $A\{\lambda_{iq}\}$, ($i = 1, 2 \dots N$). Иными словами, теперь можно работать с сигналами, как с числами, а это позволяет применять для их обработки и анализа цифровые алгоритмы любой степени сложности, практически нереализуемые в аналоговой форме, использовать в системах передачи информации цифровые методы и современные цифровые интегральные технологии и т.д.

3. Задачи и постулаты теории информации. Количественная оценка информации

3.1 Постулаты теории информации

Результаты решения целого ряда фундаментальных теоретических вопросов составляют проблемное поле теории информации, в частности:

- анализ сигналов с позиций средства передачи сообщений, который включает вопросы оценки переносимого этими сигналами «количества информации»;

- анализ инфохарактеристик каналов связи и источников сообщений, а также обоснование принципиальной возможности процессов кодирования и декодирования сообщений, которые обеспечивают максимально допустимую скорость передачи по каналу связи сообщений независимо от наличия помех.

Основные условия (постулаты) теории информации, при которых исследуются информационные системы, можно сформулировать следующим образом:

1. Источник сообщения с определенной вероятностью производит выборку сообщения из некоторого множества.

2. Сообщения по каналу связи могут передаваться в закодированном виде. При этом кодированные сообщения образуют множество, которое является взаимно однозначным отображением исходного множества сообщений. Все правила декодирования записаны в программе декодера.

3. Число сообщений неограниченно и может быть очень большим, при этом сообщения следуют друг за другом.

4. Сообщение принято верно только в том случае, если в результате декодирования это сообщение в точности восстановлено независимо от промежутка времени, прошедшего с момента передачи сообщения и до момента окончания декодирования, а также сложности операций кодирования и декодирования.

5. Общее количество информации не зависит ни в коей мере от смыслового содержания сообщения, его полезности и его эмоционального воздействия, и даже от его отношения к реальной действительности.

3.2 Количественная оценка информации

Основной характеристикой информационного сообщения в теории информации является ее **количество**. Понятие «количество информации» связано со степенью неопределенности информации и не затрагивает важности и смысла передаваемого сообщения.

Рассмотрим алфавит источника сообщений, состоящий из **m** знаков, каждый из которых может выступать элементом сообщения. Количество **N** всех возможных сообщений длиной **n** будет равно числу перестановок с неограниченными повторениями:

$$N = m^n$$

В случае равновероятного получения всех **N** сообщений от источника получение конкретного сообщения будет равносильно случайному выбору с вероятностью **1/N** одного из **N** сообщений.

*Очевидно, что тем более информативным можно будет считать это сообщение и тем большая степень неопределенности будет характеризовать этот выбор, чем больше **N**.*

По этой причине число **N** могло бы служить некоторой мерой информации. И с точки зрения теории информации, целесообразно было бы наделить эту меру свойствами *аддитивности*, т.е. чтобы она была пропорциональна длине сообщения (так при отправке сообщения-телеграммы важно общее число знаков, а не ее содержание).

За меру неопределенности выбора состояния источника сообщения с равновероятными состояниями принимают логарифм числа состояний:

$$I = \log N = \log m^n = n \log m.$$

Эта логарифмическая функция, характеризующая количество информации, была предложена в 1928 г. ученым из США Р.Хартли.

Энтропией называется количество информации, которое приходится на один элемент сообщения (букву, знак):

$$H = I/n = n \log m / n = \log m$$

На самом деле безразлично, какое именно основание логарифма будет использовано для определения энтропии и количества информации, т. к. исходя из соотношения $\log_a m = \log_a b \cdot \log_b m$ переход от одного основания логарифма к другому сводится лишь к изменению единицы измерения.

В связи с тем, что в основе современной информационной техники используются элементы, имеющие два устойчивых состояния, то выбирают обычно основание логарифма равным 2, т.е. энтропию выражают как:

$$H_0 = \log_2 m.$$

В этом случае *единицу количества информации* на один элемент сообщения называют *битом* или *двоичной единицей* (*bit* – сокр. от англ. *binary digit* — двоичная единица). При этом единица неопределенности (бит или двоичная единица) есть неопределенность выбора из двух равновероятных событий.

Так как из $\log_2 m = 1$ следует $m = 2$, то очевидно, что *1 бит - это то количество информации, которое характеризует один двоичный элемент при равновероятных состояниях 0 и 1.*

Пример 1. Требуется определить количество информации, содержащееся в телевизионном сигнале, который соответствует одному кадру развертки. Предположим, что в кадре 625 строк, а сигнал, соответствующий одной строке, есть не что иное как последовательность из 600 случайных по амплитуде импульсов, при этом амплитуда импульса может принимать любое из 8 значений с шагом в 1 В.

Решение. В этом примере длина сообщения, которая соответствует одной строке, равна числу случайных по амплитуде импульсов в ней: $n = 600$.

Количество элементов сообщения (знаков) в одной строке будет равно числу значений, принимаемое амплитудой импульсов в строке: $m = 8$.

Количество информации в одной строке: $I = n \cdot \log_2 m = 600 \cdot \log_2 8$, а количество информации в кадре: $I' = 625 \cdot I = 625 \cdot 600 \cdot \log_2 8 = 1,125 \cdot 10^6$ бит

Пример 2. Требуется определить минимальное число взвешиваний, производимое на равноплечих весах, чтобы найти одну фальшивую (более легкую) монету среди 27 внешне неотличимых монет.

Решение. В связи с тем, что монеты внешне не отличаются, то они представляют собой источник с равновероятными состояниями. При этом общая неопределенность ансамбля, которая характеризует его энтропию, составит: $H_1 = \log_2 27$ бит.

Одно взвешивание будет способно прояснить неопределенность ансамбля, который насчитывает три возможных исхода (весы находятся в равновесии, правая чаша весов легче, левая чаша весов легче). Так как все исходы равновероятны, то результат одного взвешивания есть источник с равновероятными состояниями, и его энтропия составляет: $H_2 = \log_2 3$ бит.

В связи с тем, что энтропия аддитивна и при этом $H_1 = 3H_2 = 3 \log_2 3$, то определение фальшивой монеты может быть выполнено за три взвешивания.

Рассмотрим алгоритм определения фальшивой монеты. При выполнении первого взвешивания кладется по девять монет на каждую чашку весов. Фальшивая монета окажется либо среди более легкой кучки из девяти монет, либо среди тех монет, которые не взвешивались (в случае равновесия весов). Более легкую кучку из девяти монет снова разобьем на три кучки по три монеты и произведем взвешивание. По аналогии после второго взвешивания число монет, содержащих фальшивую, сократится до трех. И третье, последнее, взвешивание позволит точно определить фальшивую монету.

Рассмотренная выше оценка информации основана на предположении о равновероятности всех знаков алфавита.

В действительности большинство источников информации не соответствуют условиям равновероятного исхода. Рассмотрим поэтому основы информационного подхода Шеннона.

Пусть имеется источник, выдающий последовательность дискретных независимых сообщений $\{x_i\}$, каждое из которых случайно выбирается из ал-

фавита сообщения $A(\lambda_i) = \lambda_1, \lambda_2, \lambda_3, \dots, \lambda_K$, здесь K - размер алфавита источника. Этот источник называется *источником без памяти* с конечным дискретным алфавитом, а сообщения, которые он вырабатывает, называются *простыми сообщениями*.

Каждое элементарное сообщение λ_i содержит для своего получателя некоторую *информацию*. Выясним от чего зависит эта количественная мера и определим ее.

До момента связи у получателя имеется некая неопределенность по отношению к тому, *какое сообщение λ_i* из числа возможных будет передано.

Очевидно, что степень этой неопределенности, или неожиданности передачи λ_i , сильно зависит от вероятности передачи того или иного сообщения. Так например, если вероятность передачи некоторого сообщения λ_i очень высока, то еще до момента связи мы практически будем знать, какое сообщение будет передано, и его получение не даст нам почти никакой новой информации.

Очевидно, что количество информации, которое содержится в элементарном сообщении λ_i , есть некоторая функция от вероятности передачи этого сообщения $P(\lambda_i)$:

$$J(\lambda_i) = \varphi\{P(\lambda_i)\}. \quad (3.1)$$

Определим вид этой функции φ . Для этого потребуем, чтобы мера количества информации $J(\lambda_i)$ удовлетворяла двум интуитивным свойствам:

1. Если выбор сообщения λ_i заранее предопределен ($P(\lambda_i) = 1$ - неопределенности нет), то *количество информации* в этом сообщении равно нулю: $J(\lambda_i) = \varphi\{1\} = 0$.

2. Если источник последовательно выбирает сообщения λ_i и λ_j и вероятность такого выбора $P(\lambda_i, \lambda_j)$ есть совместная вероятность событий λ_i и λ_j , то *количество информации в этих двух элементарных сообщениях* будет равно *сумме количеств информации в каждом из них*.

Вероятность совместного выпадения событий λ_i и λ_j $P(\lambda_i, \lambda_j)$, как известно, определяется по формуле полной вероятности

$$P(\lambda_i, \lambda_j) = P(\lambda_i) \cdot P(\lambda_j / \lambda_i) = P \cdot Q. \quad (3.2)$$

Тогда, в соответствии с требованием (2), должно выполняться условие

$$\varphi \{ P \cdot Q \} = \varphi(P) + \varphi(Q). \quad (3.3)$$

Функцией, которая удовлетворяла бы этим двум условиям, является функция вида

$$J(\lambda_i) = a \log P(\lambda_i), \quad (3.4)$$

при этом и коэффициент a , и основание логарифма могут быть выбраны произвольно. Однако для удобства (чтобы количественная мера информации была положительной) принимают $a = -1$, а основание логарифма обычно выбирают равным 2. В этом случае

$$J(\lambda_i) = -\log_2 P(\lambda_i). \quad (3.5)$$

Вычисляемая подобным образом единица измерения информации будет называться *битом информации или двоичной единицей*. Так например, если некоторое элементарное сообщение λ_i выбирается из алфавита и передается с вероятностью $P(\lambda_i) = 1/8$, то говорят, что в сообщении содержится $\log_2(1/8) = 3$ бита информации.

В некоторых случаях основание логарифма выбирают равным e . Тогда информация будет измеряться в натуральных единицах или *натах*.

Количество информации, которое содержится в одном элементарном сообщении λ_i , пока никак не характеризует источник. Ведь одни элементарные сообщения несут много информации, но передаются очень редко, другие – наоборот, передаются чаще, но несут меньший объем информации. Поэтому источник информации может характеризоваться *средним количеством информации, приходящимся на одно элементарное сообщение*, которое называется “энтропия источника” и определяется следующим образом:

$$H(\lambda) = -\sum_{i=1}^K P(\lambda_i) \cdot \log P(\lambda_i), \quad i = 1, K. \quad (3.6)$$

Энтропии, являющейся количественной мерой информативности источника, характерны следующие свойства:

1. Энтропия величина вещественная, ограниченная и неотрицательная, что вытекает из вида выражения для $H(\lambda)$ с учетом того, что $0 < P(\lambda_i) < 1$.
2. Энтропия детерминированных сообщений равна нулю, то есть $H(\lambda) = 0$, если вероятность хотя бы одного сообщения равна единице.
3. Энтропия максимальна, если сообщения λ_i равновероятны, то есть $P(\lambda_1) = P(\lambda_2) = \dots P(\lambda_K) = 1/K$, и тогда

$$H(\lambda) = -\frac{1}{K} \sum_{i=1}^K \log \frac{1}{K} = \log K. \quad (3.7)$$

Из последнего выражения видно, что в случае равновероятных сообщений энтропия будет расти с увеличением объема алфавита источника (увеличением числа сообщений). При неравновероятных элементарных сообщениях λ_i энтропия будет уменьшаться.

4. Энтропия двоичного источника ($K = 2$) изменяется от нуля до единицы. На самом деле, энтропия системы из двух сообщений λ_1 и λ_2

$$\begin{aligned} H(\lambda) &= -P(\lambda_1) * \log P(\lambda_1) - P(\lambda_2) * \log P(\lambda_2) = \\ &= -P(\lambda_1) * \log P(\lambda_1) - \{1 - P(\lambda_1)\} * \log \{1 - P(\lambda_1)\}. \end{aligned} \quad (3.8)$$

Откуда видно, что энтропия равна нулю при $P(\lambda_1) = 0$; $P(\lambda_2)=1$, или $P(\lambda_1) = 1$; $P(\lambda_2) = 0$; при этом максимум энтропии будет наблюдаться, когда $P(\lambda_1)=P(\lambda_2)=1/2$ и это максимальное значение будет равно 1 бит.

4. Вероятностно-статистические модели сообщений и их свойства

4.1 Источники дискретных сообщений и их вероятностные модели

Рассмотрим произвольный источник сообщений. Каждое сообщение представляет собой последовательность символов (0 и 1 в компьютерной логике, точки и тире в телеграфии, буквы русского алфавита и др.).

В этом сообщении отдельные символы: ξ – есть случайная величина, которая принимает все возможные значения из заданного алфавита сообщений A : $\xi \in A$.

Если мощность A конечна: $A = \{a^{(1)}, a^{(2)}, \dots, a^{(N)}\}$, $2 \leq N < \infty$, где $a^{(1)}, a^{(2)}, \dots, a^{(N)}$ – символы алфавита; N – мощность алфавита, то имеют дело с источником дискретного сообщения (ИДС). В противном случае – источником непрерывного сообщения.

Будем использовать модель ИДС как наиболее часто встречающуюся. Каждое появление символа алфавита в сообщении будет описываться дискретной вероятностной моделью.

Дискретный ансамбль B – это полная совокупность состояний (символов алфавита) с вероятностью их появления:

$$B = \begin{pmatrix} a^{(1)} & a^{(2)} & \dots & a^{(N)} \\ P(a^{(1)}) & P(a^{(2)}) & \dots & P(a^{(N)}) \end{pmatrix}, \quad \sum_{i=1}^N P(a^{(i)}) = 1, \quad 0 < P(a^{(i)}) < 1,$$

где $P(a) = P\{\xi = a\}$.

Ясно, что эта модель $\langle A, P(a) \rangle$ описывает одиночный случайный символ сообщения.

Сообщение, которое порождается ИДС – есть, в общем случае, последовательность $n \geq 1$ случайных символов: $\Xi_n = (\xi_1, \xi_2, \dots, \xi_n) \in A^n$. При этом полное вероятностное описание ИДС задается вероятностной моделью случайного временного ряда (случайного процесса) Ξ_n с дискретным временем $t \in \mathbf{N}$ и дискретным пространством состояний A , $n = 1, 2, \dots$:

$$\langle A^n, P_n(a_1, a_2, \dots, a_n) \rangle,$$

$$P_n(a_1, a_2, \dots, a_n) = P\{\xi_1 = a_1, \xi_2 = a_2, \dots, \xi_n = a_n\}, \quad a_1, a_2, \dots, a_n \in A,$$

где $P_n(a_1, a_2, \dots, a_n)$ – n -мерное дискретное распределение вероятностей n -символьного сообщения.

ИДС называется стационарным, если случайный процесс Ξ инвариантен по отношению к сдвигу начала отсчета t . Если порождаемые ИДС слу-

чайные символы одинаково распределены и независимы в совокупности, то стационарный ИДС будет являться источником без памяти.

4.2 Собственная информация

Задача количественного измерения информации возникла при необходимости решения конкретных практических задач. Так к примеру, можно пытаться уменьшить количество электрических сигналов, которые необходимы для передачи по каналам связи сообщения. Поэтому разумной мерой информации, которая содержится в сообщении, будет такая мера, которая монотонно связана с затратами на передачу сообщения.

Собственная информация $I(x)$ сообщения x , которое выбирается из дискретного ансамбля $B = \{X, P(x)\}$ – это:

$$I(x) = \log_b \frac{1}{P(x)} = -\log_b P(x). \quad (4.1)$$

Если $b = 2$, то количество информации измеряется в битах; $b = e$ – натах; $b = 10$ – ди/хартли (в 1928 г. Хартли впервые предложил эту формулу в виде

$$I(x) = -\lg \frac{1}{N}).$$

Свойства собственной информации:

1. $I(x) \geq 0, x \in X$.
2. Монотонность: если $x_1, x_2 \in X$, $P(x_1) \geq P(x_2)$, то $I(x_1) \leq I(x_2)$.
3. Аддитивность: (для независимых сообщений)

$$x_1, \dots, x_n : I(x_1, \dots, x_n) = \sum_{i=1}^n I(x_i).$$

Пример

Дан ансамбль: $B = \begin{pmatrix} 'a' & 'b' & 'c' & 'd' \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{8} & \frac{1}{8} \end{pmatrix}$. Будем производить кодирование,

используя 0 и 1.

$$I('a') = -\log_2 \frac{1}{2} = 1(\text{бит})$$

$$I('b') = 2, \quad I('c') = I('d') = 3. \bullet$$

Как видно, что чем выше вероятность появления символа в сообщении и, соответственно, чем чаще он появляется, тем меньшим числом бит его необходимо кодировать, с целью экономии на длине закодированного сообщения.

Таким образом, собственная информация характеризует степень неожиданности появления конкретного сообщения.

Пример

Определить собственную информацию, которая содержится в изображении, состоящем из 500 строк по 500 элементов в каждой строке. Каждый элемент передается 8 уровнями яркости, которая независима для различных элементов.

Решение

Случайная величина X – яркость одного элемента изображения.

$$P(x_i) = \frac{1}{n} = \frac{1}{8}.$$

$$I(x_i) = \log_2 \left(\frac{1}{8} \right)^{-1} = 3. \text{ Изображение содержит } N = 25 \cdot 10^4 \text{ элементов. Так как}$$

яркости элементов независимы, то $I(\text{image}) = N \cdot I(x_i) = 7.5 \cdot 10^5 (\text{бит}). \bullet$

Пример

На экране радара размером 10×10 полос изображение появляется в виде яркой отметки. Все положения равновероятны. Определить количество собственной информации, содержащейся в следующих сообщениях: (а) объект находится в 46 квадранте, (б) объект находится в 5-ой горизонтальной строке.

Решение

$$(a) I(x_{46}) = -\log_2 \frac{1}{100} \approx 6.644.$$

$$(б) I(x_5) = -\log_2 \frac{10}{100} \approx 3.322. \bullet$$

4.3. Взаимная информация

Рассмотрим два ансамбля сообщений: X, Y , где

$X = \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ P(x_1) & P(x_2) & \dots & P(x_n) \end{pmatrix}$ – ансамбль сообщений на входе системы,

$Y = \begin{pmatrix} y_1 & y_2 & \dots & y_m \\ P(y_1) & P(y_2) & \dots & P(y_m) \end{pmatrix}$ – на выходе.

Эти ансамбли зависимы друг от друга.

В ходе эксперимента (приема символа y_k) апостериорная вероятность появления символа x_j изменяется в сравнении с априорной. Тогда количество информации символа сообщения x_j , которое доставляется символом y_k , можно определить как логарифм отношения апостериорной вероятности к априорной:

$$I(x_j; y_k) = \log \frac{P(x_j | y_k)}{P(x_j)}. \quad (4.2)$$

Формула (4.2) определяет взаимную информацию.

Свойства взаимной информации:

$$1. -\infty < I(x_j; y_k) < \infty.$$

Если $I(x_j; y_k) < 0$, то считается, что наступление события y_k делает наступление события x_j менее вероятным, чем оно было априори до наблюдения y_k .

$$2. I(x_j; y_k) \leq I(x_j), I(x_j; y_k) \leq I(y_k) - \text{взаимная информация не превышает свою собственную.}$$

При данном $P(x_j)$ взаимная информация достигает своего максимума, когда принятый символ y_k однозначно определяет переданный символ x_j .

$$\text{При этом } P(x_j | y_k) = \begin{cases} 0, j \neq k \\ 1, j = k \end{cases} \text{ и это максимальное значение равно}$$

$I(x_j; y_k) = -\log P(x_j)$, то есть собственной информации, определяемой только априорной вероятностью символа x_j .

$$3. \text{Симметрия: } I(x_j; y_k) = I(y_k; x_j). \text{ Информация, содержащаяся в } x_j \text{ относительно } y_k, \text{ равна информации, содержащейся в } y_k \text{ относительно } x_j. \text{ Поэтому } I(x_j; y_k) - \text{это взаимная информация.}$$

$$4. \text{Аддитивность: } I(x_j, z_i; y_k, q_l) = I(x_j; y_k) + I(z_i; q_l), \text{ только при условии, что ансамбли } X, Y \text{ независимы от } Z, Q.$$

Информация, содержащаяся в реализации y_k принятого сигнала относительно ансамбля передаваемых сообщений X , определяется следующей формулой:

$$\begin{aligned} I(X; y_k) &= M \left(\log \frac{p(X | y_k)}{p(X)} \right) = \sum_{j=1}^n p(x_j | y_k) \log \frac{p(x_j | y_k)}{p(x_j)} = \\ &= \sum_{j=1}^n p(x_j | y_k) I(x_j; y_k). \end{aligned} \quad (4.3)$$

Наконец, средняя взаимная информация между ансамблем принимаемых сигналов Y и ансамблем передаваемых сообщений X определяется формулой (4.4):

$$\begin{aligned}
 I(X;Y) &= M\left(\log \frac{p(X|Y)}{p(X)}\right) = \sum_{j=1}^n \sum_{k=1}^m p(x_j; y_k) \log \frac{p(x_j | y_k)}{p(x_j)} = \\
 &= \sum_{k=1}^m p(y_k) I(X; y_k),
 \end{aligned}
 \tag{4.4}$$

т.е. то количество информации, содержащиеся в среднем в ансамбле принимаемых символов Y относительно ансамбля передаваемых символов X .

Пример.

Пусть по дискретному каналу передаются сообщения x_1 и x_2 . Из-за наличия шумов на выходе канала появляются сигналы y_1, y_2, y_3 . Вероятности их совместного появления $P(x_i; y_j)$ заданы в таблице:

	y_1	y_2	y_3
x_1	1/4	1/16	1/8
x_2	1/8	3/16	1/4

Необходимо найти взаимную информацию $I(x_2; y_2)$ и $I(x_1; y_3)$.

Решение

$$I(x_1; y_3) = \log \frac{P(x_1 | y_3)}{P(x_1)}.$$

$$P(x_1) = \sum_{j=1}^3 P(x_1; y_j) = \frac{7}{16}, \quad P(y_3) = \sum_{i=1}^2 P(y_3; x_i) = \frac{3}{8}.$$

$$P(x_1 | y_3) = \frac{P(x_1; y_3)}{P(y_3)} = \frac{1}{3}. \text{ Значит, } I(x_1; y_3) = \log_2 \frac{1/3}{7/16} \approx -0.39(\text{бит}).$$

$$\text{Аналогично: } I(x_2; y_2) = \log_2 \frac{1/3}{1/4} \approx 0.415(\text{бит}). \bullet$$

Заметим, что среднее значение, или математическое ожидание, вычисленные по ансамблю, будут характеристикой информативности всего ансамбля: для этого вводят понятие энтропии.

5. Энтропия

Предположим, что ИДС может быть описана некоторым дискретным ансамблем: $X = \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ P(x_1) & P(x_2) & \dots & P(x_n) \end{pmatrix}$. Тогда энтропия ИДС (или иначе энтропия случайного символа ξ) может быть вычислена по формуле (5):

$$H(\xi) = M(I(\xi)) = M(-\log P(\xi)) = -\sum_{i=1}^n P(x_i) \log P(x_i). \quad (1.5)$$

Впервые приведенная выше мера была предложена Клодом Шенноном в работе “Математическая теория связи”. Эта формула совпала с более ранним результатом Больцмана для случая энтропии термодинамических систем.

В общем случае энтропия может быть интерпретирована как количественная мера априорной неосведомленности о сообщении, которое будет порождено источником (т.е., какой из x_j подастся на вход). Как видим, энтропия – есть мера неопределенности. Одновременно встречается и другое определение энтропии – среднее количество собственной информации.

Энтропия обладает следующими характерными свойствами:

1. $H(\xi) \geq 0$.

$H(\xi) = 0$, если ξ неслучайно.

2. $H(\xi) \leq \log n$.

$H(\xi) = \log n$, если $P(x_i) = \frac{1}{n}$. Такое возможно, если все сообщения x_i равновероятны или источник без памяти.

3. Аддитивность: в последовательности из m независимых символов энтропия будет равна сумме энтропий, которые содержатся в отдельных символах:

$$H[\xi_1, \dots, \xi_m] = \sum_{i=1}^m H(\xi_i).$$

4. Для ансамблей с одинаково распределенными вероятностями, отличающихся только порядком следования элементов, энтропии равны.

Пример 1

Пусть на измерительной станции есть 2 прибора:

Первый имеет 100 делений, его показания меняются каждые 0.05 секунды.

Второй имеет 10 делений, его показания меняются каждые 0.01 секунды.

Какова наибольшая средняя информация, поставляемая двумя приборами в 1 секунду?

Решение

Так как все деления на приборах равновероятны, то энтропия 1-ого прибора:

$$H_1^{2-ое\ св-во} = \log_2 100. \text{ Аналогично для 2-ого прибора: } H_2 = \log_2 10.$$

Число измерений в секунду *первым* прибором: $n_1 = \frac{1}{0.05} = 20$, *вторым*

$n_2 = \frac{1}{0.01} = 100$. Энтропия двух приборов в 1 секунду (их показания незави-

симы друг от друга): $H^{3-ее\ св-во} = n_1 H_1 + n_2 H_2 \approx 464 (\text{бит/сек}). \bullet$

Пример 2

Производится стрельба по двум мишеням. По *первой* сделано 2 выстрела, по *второй* – 3. Вероятности попадания при одном выстреле: $1/2$ и $1/3$ соответственно. Исход стрельбы (при одном попадании) по какой мишени более не определен?

Решение

Исход стрельбы будет определяться числом попаданий в мишень, подчиняющемуся биномиальному закону распределения:

$P(\xi = m) = C_n^m p^m (1-p)^{n-m}$. Здесь m – это число попаданий в мишень, p – вероятность попадания в мишень.

Ряд распределения для числа попаданий в *первую* мишень при $n = 2$ (число выстрелов по мишени) и при вероятности попадания в мишень $p = \frac{1}{2}$ приведен далее.

m	0	1	2
$P(\xi = m)$ (вероятность m попаданий)	1/4	1/2	1/4

Аналогично – запишем ряд для *второй* мишени:

m	0	1	2	3
$P(\xi = m)$ (вероятность m попаданий)	8/27	4/9	2/9	1/27

Мера неопределенности исхода стрельбы – это энтропия числа попаданий по мишени.

Энтропия при стрельбе по *первой* мишени:

$$H_1 = -\sum_{i=1}^3 P(x_i) \log_2 P(x_i) = -\left[2 \cdot \frac{1}{4} \log_2 \frac{1}{4} + \frac{1}{2} \log_2 \frac{1}{2} \right] \approx 1.5(\text{бит}).$$

Энтропия при стрельбе по *второй* мишени: $H_2 = 1.7(\text{бит})$.

Таким образом, исход стрельбы по 2-ой мишени обладает большей неопределенностью. ●

1.1.1 Условная энтропия

Имеем два статистически независимых конечных ансамбля символов X, Y . Пары символов $x_j y_k$ с вероятностью $P(x_j, y_k)$ – есть элементарные символы объединенного ансамбля XY с энтропией, которая вычисляется по формуле (6):

$$H(XY) = - \sum_{j=1}^n \sum_{k=1}^m P(x_j, y_k) \log P(x_j, y_k). \quad (1.6)$$

Появление символа x_j будет вызывать появление символа y_k с вероятностью

$$P(y_k | x_j) = \frac{P(x_j, y_k)}{P(x_j)}.$$

Частная условная энтропия:

$$H(Y | x_j) = M(-\log P(Y | x_j)) = - \sum_{k=1}^m P(y_k | x_j) \log P(y_k | x_j). \quad (1.7)$$

Средняя условная энтропия ансамбля Y при условии, что ансамбль X известен:

$$\begin{aligned} H(Y | X) &= \sum_{j=1}^n P(x_j) H(Y | x_j) = - \sum_{j=1}^n P(x_j) \sum_{k=1}^m P(y_k | x_j) \log P(y_k | x_j) = \\ &= - \sum_{j=1}^n \sum_{k=1}^m P(x_j, y_k) \log P(y_k | x_j). \end{aligned} \quad (1.8)$$

Свойства условной энтропии:

1. $H(XY) = H(X) + H(Y | X) = H(Y) + H(X | Y)$, если X, Y зависимы.

Кроме того:

$$H(X_1, X_2, \dots, X_n) = H(X_1) + H(X_2 | X_1) + \dots + H(X_n | X_1, X_2, \dots, X_{n-1}).$$

2. $H(XY) = H(X) + H(Y)$, при условии, что X, Y независимы.
3. $\frac{H(Y | X)}{H(X | Y)} \leq \frac{H(Y)}{H(X)}$, при этом равенство только в случае независимости X, Y .
4. $H(X | Y) \geq 0$.
5. $H(X | YZ) \leq H(X | Y)$.

Равенство будет только в случае условной независимости X, Y при любых $z \in Z$.

Приведем формулы для *связи* энтропии и средней взаимной информации:

1. $I(X, Y) = H(X) + H(Y) - H(XY) = H(Y) - H(Y | X)$.
2. $I(X, Y) = H(Y) - H(Y | X) = H(X) - H(X | Y)$.
3. $I(X, X) = H(X)$, откуда видно, что энтропия – есть частный случай функционала средней взаимной информации.
4. $0 \leq I(X, Y) \leq \min(H(X), H(Y))$.

При этом равенство нулю возможно только в случае статической независимости X, Y .

Пример

Необходимо вычислить энтропию $H(X)$, среднюю взаимную информацию $I(X, Y)$, условную энтропию $H(X | Y)$, если известно $P(x_j, y_i)$ двух ансамблей X, Y :

	x_1	x_2	$P(y_i)$
y_1	0.5	0	0.5
y_2	0.25	0.25	0.5
$P(x_j)$	0.75	0.25	

Решение

Найдем $P(x_j | y_i) = \frac{P(x_j, y_i)}{P(y_i)}$:

	x_1	x_2
y_1	1	0
y_2	0.5	0.5

Энтропия $H(X | y_1) = 0$,

$$H(X | y_2) = 1,$$

$$H(X | Y) = 0.5 \cdot 0 + 0.5 \cdot 1 = 0.5,$$

$$H(X) = -0.75 \log_2 0.75 - 0.25 \log_2 0.25 \approx 0.811.$$

Средняя взаимная информация: $I(Y, X) = H(X) - H(X | Y) \approx 0.311$.●

1.1.2 Избыточность

Считается, что избыточность имеет место, если количество информации, которая содержится в сигнале (энтропия сигнала), меньше количества, которое этот сигнал мог бы содержать по своей физической природе.

Предположим, что сигнал длиной n символов содержит количество информации H ; кроме этого, наибольшее количество информации, содержащиеся в данном сигнале с учетом всех наложенных ограничений (например, заданная средняя мощность сигнала, основание кода и др.), будет равно $H_{\max}$. Тогда количественной мерой избыточности будет являться величина:

$$K = 1 - \frac{H}{H_{\max}}. \quad (1.9)$$

Причиной избыточности являются статистические связи между символами сигнала, а также неэкстремальность распределения вероятностей его отдельных символов. Введение избыточности приводит к удлинению сигнала, но одновременно с этим повышает его информационную устойчивость при воздействии различных помех.

Статистические связи между сигналами всегда наблюдаются в случае ИДС с памятью: в этом случае вероятность выдачи очередного элемента сообщения x_j зависит от ранее выданных элементарных сообщений.

Примером ИДС с памятью может быть источник связанного русского текста, в котором элементарными сообщениями являются буквы. Например сочетание 'ар' встречается чаще, чем сочетание 'аб'.

Избыточность показывает при заданном объеме алфавита долю максимально возможной неопределенности (энтропии), не используемой источником.

Пример

Пусть дан ансамбль: $X = \begin{Bmatrix} x_1 & x_2 & x_3 & x_4 & x_5 & x_6 \\ 0.4 & 0.2 & 0.15 & 0.1 & 0.1 & 0.05 \end{Bmatrix}$, в котором символы в последовательности независимы. Требуется найти энтропию источника и вычислить избыточность.

Решение

Энтропия: $H(X) \approx 2.27(\text{бит})$.

Избыточность за счет неоптимальности (не равновероятности) распределения элементарных сообщений в источнике: $K = 1 - \frac{2.27}{H_{\max}} \approx 0.13$, где $H_{\max} = \log_2 6$.

6. Основные принципы кодирования

Под *кодированием* понимают *преобразование алфавита* исходного сообщения $A\{\lambda_i\}$, ($i = 1, 2 \dots K$) в алфавит определенным способом подобранных кодовых символов $\mathcal{R}\{x_j\}$, ($j = 1, 2 \dots N$). Как правило (но не всегда) размерность алфавита кодовых символов $\dim \mathcal{R}\{x_j\}$ значительно меньше размерности алфавита первоисточника $\dim A\{\lambda_i\}$.

Цели у кодирования сообщений могут быть различные. Например, кодирование для засекречивания передаваемого сообщения. В этом случае элементарным сообщениям λ_i из исходного алфавита $A\{\lambda_i\}$ ставятся в соответствие определенные последовательности цифр или букв из специальных кодовых таблиц, которые известны только получателю и отправителю информации.

Помехоустойчивое кодирование или кодирование в канале информации используется с целью снижения количества ошибок, возникающих в процессе передачи по каналу, имеющему помехи.

Ну и наконец, сообщения могут кодироваться для *уменьшения объема передаваемой информации и увеличения скорости передачи информации, а также сокращения полосы частот, необходимых для передачи информации*. Подобное кодирование называется *экономным (безызбыточным, эффективным) кодированием или сжатием данных*. В настоящем разделе речь будет идти как раз об этом виде кодирования. Процессу кодирования как правило предшествуют (и встраиваются в него) процедуры дискретизации и квантования непрерывного исходного сообщения $\lambda(t)$, заключающиеся в преобразовании исходного сообщения в последовательность простейших дискретных сообщений $\{\lambda_{iq}\}$.

Выделяют сжатие с потерями информации и сжатие без потери информации.

В системах кодирования неразрушающего сжатия декодер регенерирует данные первоисточника абсолютно без потерь информации (рис. 6.1).



Рис. 6.1. Схема сжатия без потерь

X – последовательность длины n , состоящая из символов алфавита A .

$B(X)$ – сжатые данные, представленные во передаваемой последовательности длиной m ; где m зависит от n .

Существует такой термин: коэффициент сжатия r , определяемый по формуле :

$$r = \frac{\text{размер данных источника}}{\text{размер сжатых данных}} = \frac{n \log_2 |A|}{m}.$$

В случае системы сжатия с потерями информации или разрушающего сжатия процесс будет выглядеть в виде схемы, изображенной на рис.6.2.




Рис. 6.2. Схема сжатия с потерями

В этой схеме квантователь уменьшает размер алфавита (например, за счет округления данных). Между множествами X^q и $B(X^q)$ существует однозначное соответствие, но в целом система будет разрушающей, так как при таком подходе двум абсолютно различным последовательностям X_1 и X_2 может соответствовать один и тот же X^* .

В этом случае рассматривают понятие искажение сообщения:

$D = \frac{1}{n} \sum_i (x_i - x_i^*)^2$, являющееся мерой среднеквадратичного различия между сообщениями X и X^* .

В нашем курсе будем рассматриваться только кодеры, в основе которых лежит система сжатия без потерь информации.

6.1. Принципы кодирования

Рассмотрим немного подробнее суть процедуры кодирования.

Любое дискретное сообщение λ_i из алфавита источника $A\{\lambda_i\}$ объемом в K символов может быть закодировано последовательностью определенным образом выбранных кодовых символов x_j из алфавита $\mathcal{R}\{x_j\}$.

Так любое число (λ_i в общем случае можно считать числом) может быть следующим образом записано в заданной позиционной системе счисления:

$$\lambda_i = M = x_{n-1} \cdot m^{n-1} + x_{n-2} \cdot m^{n-2} + \dots + x_0 \cdot m^0, \quad (6.1)$$

где m - основание системы счисления; $x_0 \dots x_{n-1}$ - коэффициенты при степенях m ; $x \in 0, m - 1$.

Например, значение $\lambda_i = M = 59$. Код этого числа по основанию $m = 8$, будет следующим

$$M = 59 = 7 \cdot 8^1 + 3 \cdot 8^0 = 73_8.$$

А код этого же числа, но по другому основанию, например $m = 4$ будет выглядеть таким образом:

$$M = 59 = 3 \cdot 4^2 + 2 \cdot 4^1 + 3 \cdot 4^0 = 323_4.$$

Если же основание кода принять равным $m = 2$, то

$$M = 59 = 1 \cdot 2^5 + 1 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0 = 111011_2.$$

Как видим, числа **73**, **323** и **111011** могут выступать, соответственно, как восьмеричный, четверичный и двоичный код числа $M = 59$.

Таким образом, основание кода может быть любым, но наибольшее распространение получили коды с основанием **2** или *двоичные коды* с размером алфавита кодовых символов $\mathcal{X} \{x_j\}$ равным двум и содержащим только нули и единицы, $x_j \in 0,1$. Двоичные коды достаточно легко формируются и далее передаются по любым каналам связи. А также бесспорным преимуществом двоичных кодов является тот факт, что они служат внутренним языком всех цифровых ЭВМ, т.е. без каких-либо дополнительных преобразований могут обрабатываться цифровыми средствами электроники. Поэтому, в случае когда речь заходит о кодировании и кодах, то как правило имеют в виду *двоичные коды*. В дальнейшем и мы будем рассматривать в основном двоичное кодирование.

Наиболее простым способом задания кодов и их представления являются кодовые таблицы, которые ставят в соответствие сообщениям λ_i необходимые коды (табл. 6.1).

Таблица 6.1

Буква λ_i	Число λ_i	Код с основанием 10	Код с основанием 4	Код с основанием 2
А	0	0	00	000

Б	1	1	01	001
В	2	2	02	010
Г	3	3	03	011
Д	4	4	10	100
Е	5	5	11	101
Ж	6	6	12	110
З	7	7	13	111

Другой удобный и наглядный способ описания кодов – их представление в виде кодового дерева (рис. 6.3).




Рис. 6.3

Для построения кодового дерева для выбранного кода, начиная с определенной точки – *корня* кодового дерева – строятся ветви – 0 или 1. В *вершинах* кодового дерева располагаются буквы алфавита источника. При этом каждой букве алфавита источника соответствуют своя вершина и *свой путь от корня к вершине*. Например, букве А соответствует код 000, букве В – 010, букве Е – 101 и т.д.

На рис. 6.3 изображен пример *равномерного трехразрядного кода*.

Равномерные коды широко применяются из-за своей простоты и удобства процесса кодирования-декодирования: каждой букве соответствует равное число бит; после приема заданного числа бит осуществляется поиск в кодовой таблице соответствующей буквы.

Одновременно с равномерными кодами применяются и неравномерные коды, у которых каждая буква из алфавита источника кодируется различным числом символов, например, А - 10, Б - 110, В - 1110 и т.д.

Для неравномерного кодирования кодовое дерево может выглядеть, так, как показано на рис. 6.4.




Рис. 6.4

При использовании неравномерного кода букве А будет соответствовать код 1, Б - 0, В - 11 и т.д. Однако нетрудно заметить, что, закодировав, произвольный текст АББА = 1001 подобным образом, мы не можем его однозначно декодировать, так как такой же код имеют фразы: ЖА = 1001, АЕА = 1001 и ГД = 1001. Подобные коды, не позволяющие однозначно декодировать сообщение, называются *непрефиксными или приводимыми* кодами. Они не применяются на практике без специальных разделительных символов. Примером такого типа кодов является азбука Морзе, в которой кроме тире и точек есть специальные символы разделяющие слова и буквы. Но это уже не двоичный код.

Тем не менее возможно составить неравномерные неприводимые коды, дающие возможность однозначного декодирования. Для этого необходимо поставить в соответствие всем буквам алфавита вершины кодового дерева (рис. 6.5). На приведенном рисунке неоднозначности декодирования не существует, так как ни одна кодовая комбинация не является началом другой,

более длинной кодовой комбинации. Подобные неравномерные коды носят название префиксных.




Рис. 6.5

Таким образом, эффективность кодирования кодирующего устройства определяется следующими его свойствами:

1. Обеспечение безошибочной передачи информации, т.е. однозначное взаимное соответствие между X и Y .
2. Обеспечение кодирования с минимальной избыточностью наиболее экономным образом.

Для выполнения *первого* требования необходимо:

- а. Чтобы различным буквам алфавита ставились в соответствие различные кодовые слова.
- б. Чтобы предусматривалась возможность разделения кодовых слов в случае их последовательной передачи. Для этого:
 - вводят и применяют специальные разделяющие символы;
 - используют кодовые слова равной длины (равномерное кодирование);

- кодовая таблица составляется так, чтобы никакое кодовое слово не служило началом другого кодового слова.

Для выполнения *второго* требования нужно стремиться при кодировании к минимизации средней длины кодового слова: $\bar{l} = \sum_{k=1}^s l_k P(x_k)$. Здесь l_k – длина

k -ого слова x_k вместе с разделительной буквы (в случае ее использования).

Рассмотрим некоторые базовые методы эффективного кодирования.

6.2. Алгоритмы сжатия без потерь.

Выделяют две категории методов сжатия без потерь:

1. Методы сжатия источников данных без памяти (т.е. не учитывающие последовательность символов).
2. Методы сжатия источников данных с памятью.

6.2.1. Сжатие способом кодирования серий (RLE).

Кодирование серий последовательностей (Run Length Encoding - RLE) – это наиболее известный и простой подход сжатия информации обратимым путем. Суть методов этого подхода заключается в замене серий или цепочек повторяющихся байтов или последовательностей байтов на один кодирующий байт и счетчик числа повторений исходных байтов.

RLE –первый вариант.




В описываемом алгоритме признаком счетчика (counter) являются единицы в двух верхних битах считанного сообщения, а оставшиеся 6 бит

используются для записи показаний счетчика, который может принимать значения от 1 до 64. Таким образом, строка из 64 повторяющихся байтов превращается в два байта, т.е. сжимается в 32 раза.

Алгоритм используется для работы с деловой графикой – изображениями со значительными повторяющимися цветовыми областями. Однако, не так уж редка ситуация, когда при использовании этого простого алгоритма файл увеличивается,. Это может произойти в случае применения группового кодирования к уже обработанным цветным фотографиям. Для увеличения изображения в два раза, алгоритм необходимо применить к изображению, в котором значения всех пикселей больше двоичного 11000000 и попарно подряд не повторяются.

RLE –Второй вариант.

Другой вариант RLE-алгоритма имеет большую по сравнению с первым максимальную степень сжатия и в меньшей степени увеличивает исходный файл в размерах.



Признаком повтора в этом варианте алгоритма служит единица в старшем разряде соответствующего байта.

Проблема всех подобных методов состоит в определении способа, по которому распаковывающий алгоритм отличает в результирующем потоке байтов кодированную серию от других - некодированных последовательностей байтов. Эта проблема решается как правило постановкой специальных меток в начале кодированных цепочек. В качестве меток могут использоваться значения первого байта кодированной серии, характерные значения битов в первом байте кодированной серии и т.п. Эти методы являются доста-

точно эффективными для сжатия растровых графических изображений (TIF, PCX, BMP, GIF), т.к. они содержат достаточно много длинных цепочек повторяющихся последовательностей байтов. Недостатком метода RLE является довольно низкая степень сжатия или стоимость кодирования файлов с малым числом серий и с малым числом повторяющихся байтов в сериях.

Пример: имеется текст (шестнадцатиричный) вида

05 05 05 05 05 05 01 01 03 03 03 03 03 05 03 FF FF FF FF

из 20 байт. В качестве префикса выберем байт FF. Тогда на выходе архиватора будем иметь последовательность

FF 06 05 FF 02 01 FF 06 03 FF 01 05 FF 01 03 FF 04 FF.

Длина последовательности 18 байт, то есть некоторое сжатие достигнуто. Однако, как видно, при кодировании некоторых символов возрастает размер выходного кода (например, FF 02 01 вместо 01 01). Из этого следует, что одиночные или малое число раз (дважды, трижды) повторяющиеся символы кодировать нецелесообразно - их надо записывать в явном виде. Получим новую последовательность длиной 13 байт:

FF 06 05 01 01 FF 06 03 05 03 FF 04 FF

со степенью сжатия: $13/20 = 65\%$.

Как видно из примера, префикс может совпасть с одним из входных символов. В этой ситуации входной символ заменяется своим “префиксным” представлением (так FF то же самое, что и FF 01 FF – вместо одного три байта).

Таким образом, качество алгоритма сжатия зависит от правильного выбора префикса, так как, если бы в исходном тексте нашего примера одиночные символы FF встречались часто, размер выходного текста превысил бы входной. В общем случае необходимо в качестве префикса выбирать самый редкий символ входного алфавита.

Можно сделать еще один шаг, повышающий степень сжатия сообщения – в одном байте объединить префикс и длину. Пусть префикс-число F0...FF, где вторая цифра определяет длину *length* от 0 до 15. В этом случае

выходной код будет двухбайтным, но при этом сужается диапазон представления длины с 255 до 15 символов и появляются еще более жесткие ограничения на выбор префикса. Выходной текст для этого случая будет выглядеть следующим образом:

F6 05 F2 01 F6 03 05 03 F4 FF.

Степень сжатия-50%, длина-10 байт. Далее, в связи с тем, что мы условились не кодировать последовательность длиной от 0 до 3, код length очень удобно использовать с некоторым смещением (на три), то есть 00=3, 0F=18, FF=258, упаковывая таким образом более длинные цепочки за один раз. Если одиночные символы встречаются редко, то удобной может оказаться модификация алгоритма RLE без префикса, только <length,symbol>. В этом случае одиночные символы также обязательно должны кодироваться в префиксном виде, чтобы декодировщик мог различить их в выходном потоке:

03 01 05 01 03 04 FF

Степень сжатия-60%, длина-12 байт. Возможен также вариант алгоритма, в котором вместо длины length кодируется позиция относительно начала текста distance первого символа, отличающегося от предыдущего. В нашем примере это будет выходная строка вида:

01 05 07 01 09 03 0F 05 10 03 11 FF.

Описанный алгоритм и его модификации применяется в основном для работа в реальном масштабе времени и в потоке.

6.2.2. Методы сжатия источников без памяти

1. Алгоритм Хаффмана

Основная идея алгоритма заключается в том, что зная вероятность вхождения символов в сообщение, можно описать процедуру построения кодов переменной длины состоящих из целого количества битов. Символам с большей вероятностью присваиваются более короткие коды. Коды Хаффмана обладают свойством префикса, что и позволяет однозначно их декодиро-

вать, несмотря на их переменную длину. Алгоритм Хаффмана состоит из следующих шагов:


1. Символы входного алфавита составляют список свободных узлов. Каждый лист имеет вес, который может быть равен либо вероятности, либо количеству вхождений символа в ожидаемое сообщение.
2. Выбираются 2 свободных узла дерева с наименьшими весами.
3. Создается родитель с весом равным их суммарному весу.
4. Родитель добавляется в список свободных узлов, а двое его детей удаляются из этого списка.
5. Одной дуге выходящей из родителя ставится в соответствие бит 1, другой - бит 0.
6. Далее пункты повторяются, начиная со второго, до тех пор, пока в списке свободных узлов не останется только один свободный узел. Он и будет считаться корнем дерева.

Пусть мы имеем таблицу частот:

15	7	6	6	5
A	B	C	D	E


На первом шаге выбираем из листьев дерева два листа с наименьшими весами - D и E. Присоединяем их к новому узлу-родителю, вес которого устанавливается равным $11=5+6$. Затем эти узлы (D и E) удаляются из списка свободных. Узел D соответствует ветви 0 родителя, узел E - ветви 1.

На следующем этапе то же самое происходит с узлами B и C, так как именно они теперь имеют самый меньший вес в дереве. Создается новый узел с весом 13, а узлы B и C удаляются из списка свободных. После всего этого дерево кодирования принимает вид.



Далее "наилегчайшей" парой оказываются узлы В/С и D/E. Для этих узлов еще раз создается родитель, но теперь уже с весом 24. Узел В/С соответствует ветви 0 родителя, D/E соответствует ветви 1. На последнем шаге работы алгоритма в списке свободных остается только два узла – узел А и узел (В/С)/(D/E). В очередной раз создается родитель с весом 39 и бывшие свободные узлы присоединяются к разным его ветвям.

Так как свободным остается только один узел, то алгоритм построения дерева кодирования Хаффмана на этом завершается. Н-дерево представлено



на рисунке.

Для определения кода для каждого из символов, входящих в сообщение, необходимо пройти путь от листа дерева, соответствующего этому символу, до корня дерева, накапливая биты при перемещении по ветвям дерева. Полученная подобным образом последовательность битов будет являться кодом данного символа, которая записана в обратном порядке. Коды Хаффмана для приведенной выше таблицы символов будут выглядеть следующим образом.

А 0
В 100
С 101

D 110

E 111

Так как ни один из полученных кодов не является префиксом другого, они однозначно декодируются при чтении их из потока. Более того, наиболее частый символ сообщения А закодирован наименьшим количеством битов, а наиболее редкий символ Е - наибольшим.

Недостатком приведенного способа кодирования является то, что вместе с закодированным сообщением требуется передача построенной таблицы кодов (дерева), что понижает величину сжатия. Но здесь выходом из ситуации может служить динамический алгоритм построения дерева Хаффмана, в котором кодовая таблица обновляется непосредственно кодировщиком и (аналогично и синхронно) декодировщиком в ходе работы после получения очередного символа. Получаемые в этом случае коды являются квазиоптимальными, поэтому текст сжимается немного хуже. Одновременно, возрастают время работы программы и сложность алгоритма, поэтому, в настоящее время статический алгоритм полностью вытеснил динамический.

Еще одним вариантом алгоритма Хаффмана является фиксированный алгоритм Хаффмана, объединяющий в себе достоинства двух предыдущих алгоритмов – простоту, высокую скорость работы и отсутствие дополнительного словаря, дающего излишнюю избыточность. Основная идея этого алгоритма состоит в использовании некоторого усредненного по ряду текстов дерева, одинакового для кодировщика и декодировщика. Такое дерево не требует построения и передачи вместе с текстом, а следовательно отпадает потребность в выполнении первого прохода. Однако, с другой стороны, усредненное фиксированное дерево является еще более неоптимальным по сравнению с динамическим. Поэтому, иногда оказывается удобным иметь несколько фиксированных деревьев для различных видов информации.

6.2.3. Арифметическое кодирование

В 70-е годы появилось арифметическое кодирование, ставшее достойным конкурентом алгоритма Хаффмена. В основе метода лежит идея преобразования входного потока в одно число с плавающей запятой. Очевидно, что чем длиннее сообщение, тем более длинным получается в результате кодирования число. Таким образом, на выходе арифметического компрессора получается число, лежащее в интервале от 0 до 1. Это число позволяет однозначно восстановить последовательность символов, которые являлись первичной информацией.

В качестве примера рассмотрим работу арифметического компрессора на сообщении "BILL GATES".

Поставим соответствующую каждому символу сообщения вероятность появления его в сообщении (табл. 6.2).

Таблица 6.2 Вероятности появления символов в сообщении

Символ	Вероятность
Пробел	1/10
A	1/10
B	1/10
E	1/10
G	1/10
I	1/10
L	2/10
S	1/10
T	1/10

Затем присвоим каждому символу интервал вероятности его появления в сообщении из интервала от 0 до 1. При этом, положение интервала вероятности для каждого символа не важно. Имеет значение только тот факт, чтобы кодер и декодер располагали символы по одним и тем же правилам. Интервалы вероятности для символов выбранного нами сообщения приведены в табл. 6.3.

Таблица 6.3 Интервалы вероятностей для символов сообщения

Символ	Вероятность	Интервал
Пробел	1/10	[0.00, 0.10]
A	1/10	[0.10, 0.20]
B	1/10	[0.20, 0.30]
E	1/10	[0.30, 0.40]
G	1/10	[0.40, 0.50]
I	1/10	[0.50, 0.60]
L	2/10	[0.60, 0.80]
S	1/10	[0.80, 0.90]
T	1/10	[0.90, 1.00]

В общем виде алгоритм арифметического кодирования может быть описан следующим образом:

НижняяГраница = 0.0; ВерхняяГраница = 1.0;

Пока ((ОчереднойСимвол = ДайОчереднойСимвол()) != КОНЕЦ)

Интервал = ВерхняяГраница - НижняяГраница;

ВерхняяГраница = НижняяГраница + Интервал * ВерхняяГраницаИнтервалаДля(ОчереднойСимвол);

НижняяГраница = НижняяГраница + Интервал * НижняяГраницаИнтервалаДля(ОчереднойСимвол);

Конец Пока

Выдать (НижняяГраница)

Для нашего примера этот алгоритм будет работать так, как показано в табл. 6.4.

Таблица 6.4 Шаги алгоритма арифметического кодирования при обработке сообщения

Очередной символ	Нижняя граница	Верхняя граница
	0.0	1.0
B	0.2	0.3
I	0.25	0.26
L	0.256	0.258
L	0.2572	0.2576

ПРОБЕЛ	0.25720	0.25724
G	0.257216	0.257220
A	0.2572164	0.2572168
T	0.25721676	0.2572168
E	0.257216772	0.257216776
S	0.2572167752	0.2572167756

В итоге, согласно схеме алгоритма, число 0.2572167752 однозначным образом осуществляет кодирование сообщения "BILL GATES". Сам алгоритм арифметического декодирования может быть описан так:

Число = ПрочитатьЧисло();

Всегда

Символ

=Найти_Символ_В_интервал_Которого_Попадает_Число(Число)

Выдать (Символ) Интервал = ВерхняяГраницаИнтервалаДля (Символ) - НижняяГраницаИнтервалаДля (Символ);

Число = Число - НижняяГраницаИнтервалаДля(Символ);

Число = Число / Интервал;

Конец Всегда

Особенности арифметического сжатия:

Позволяет сжимать лучше, чем алгоритм Хаффмана, но работает медленнее из-за необходимости выполнения арифметических операций с рациональными дробями.

6.2.4. Методы сжатия источников с памятью

Входную последовательность символов в сообщении можно рассматривать в виде последовательности строк, которые содержат произвольное количество символов. Основная идея словарных методов заключается в замене строк символов на коды, которые можно трактовать как индексы строк некоторого словаря.

Таким образом, происходит попытка преобразовать исходную последовательность символов сообщения так, что его "буквы" являются фразами словаря, состоящими, в общем случае, из произвольного количества символов входной последовательности.

Словарь — это набор отдельных фраз, которые, предположительно, будут появляться в обрабатываемой последовательности. Индексы фраз строятся таким образом, чтобы их представление в среднем занимало меньше места, чем требуется для замещаемых строк. Это и позволяет осуществлять сжатие.

1. Классические алгоритмы Зива-Лемпела

Алгоритмы словарного сжатия Зива-Лемпела были разработаны во второй половине 1970-х годов. К ним относятся алгоритмы LZ77 и LZ78, созданные совместно Зивом (Ziv) и Лемпелом (Lempel). Со временем первоначальные схемы алгоритмов подвергались множественным доработкам и изменениям, в результате чего на сегодняшний день имеется десятки достаточно самостоятельных алгоритмов сжатия и бесчисленное количество их модификаций.

LZ77 и LZ78 являются универсальными алгоритмами сжатия, в которых словарь формируется адаптивно на основании уже обработанной некоторой части входного потока. Принципиальным отличием алгоритмов друг от друга является лишь способ формирования фраз. В модификациях первоначальных алгоритмов это свойство сохраняется. Поэтому словарные алгоритмы Зива-Лемпела разделяют на два семейства — алгоритмы типа LZ77 и алгоритмы типа LZ78. Иногда также говорят о словарных методах LZ1 и LZ2.


Если исследователь алгоритмов сжатия существенно изменял какой-то алгоритм, относимый к семейству LZ, то в названии полученной модификации к строчке "LZ" обычно дописывалась первая буква его фамилии, например: алгоритм LZB, автор Белл (Bell).

Этот словарный алгоритм сжатия является самым старым среди методов LZ. Описание было опубликовано в 1977 году, но сам алгоритм разработан не позднее 1975 года.

LZ77. Является "родоначальником" целого семейства словарных схем — так называемых алгоритмов со скользящим словарем, или скользящим окном. В LZ77 в качестве словаря используется блок уже закодированной последовательности. Как правило, по мере выполнения обработки положение этого блока относительно начала последовательности постоянно меняется, словарь "скользит" по входному потоку данных.

LZSS. Эта модификация LZ77 была предложена Сторером (Storer) и Жимански (Szymanski) в 1982 году. Идея алгоритма заключается в добавление к каждому указателю и символу однобитового префикса, который позволяет различать эти объекты.

В потоке сжатых данных идет либо пара <счетчик, смещение относительно текущей позиции>, либо просто <счетчик> "пропускаемых" байт и сами значения байтов (как во втором варианте алгоритма RLE). При разархивации для пары <счетчик, смещение> копируются <счетчик> байт из выходного массива, полученного в результате разархивации, на <смещение> байт раньше, а <счетчик> (т.е. число равное счетчику) значений "пропускаемых" байт просто копируются в выходной массив из входного потока.



LZW. Название алгоритм получил по первым буквам фамилий его разработчиков — Lempel, Ziv и Welch и является модификацией алгоритма LZ78. За счет предварительного занесения в словарь всех символов алфавита входной последовательности результат работы LZW состоит только из по-

следовательности индексов фраз словаря. Из-за устранения необходимости регулярной передачи одного символа в явном виде LZW обеспечивает луч-

0	'0'
...	...
255	'255'
256	ClearTable
257	EndOfInformation
258	
259	
...	
4095	

шее сжатие, чем LZ78.

Таблица словаря для LZW состоит из 4096 строк.

коды 256 и 257 являются служебными.

258 ... 4095 содержат непосредственно сжимаемую информацию.

7. Помехоустойчивое кодирование

Рассмотренные нами базовые принципы экономного кодирования данных описывают основы кодирования источника информации в системах передачи данных. Задача кодера источника заключается в *представлении передаваемых данных в неискаженной (по возможности) и максимально компактной форме.*

В процессе передачи информации по каналу связи с помехами в принятом пакете данных могут появляться ошибки. Если эти ошибки незначительны или возникают не часто, то информация может использоваться потребителем. При достаточно большом количестве ошибок получаемой информацией пользоваться нельзя.

Уменьшению числа ошибок, возникающих в процессе передачи информации по каналу с помехами, будет способствовать *помехоустойчивое кодирование* или *кодирование в канале.*

Возможность использования кодирования с целью уменьшения количества ошибок в канале теоретически была показана в 1948 году К. Шенноном в работе "Математическая теория связи", где утверждалось, что «если скорость создания источником сообщений (производительность источника) не превосходит некоторой величины, называемой пропускной способностью

канала, то при соответствующем кодировании и декодировании можно свести вероятность ошибок в канале к нулю».

Тем не менее, вскоре выяснилось, что фактические ограничения на скорость передачи информации определяются сложностью схем кодирования и декодирования, а не пропускной способностью канала передачи. Именно поэтому все усилия исследователей и разработчиков в последние годы были нацеливались на поиск наиболее эффективных кодов для схем кодирования и разработку таких схем кодирования и декодирования, которые могли бы быть практически реализованы и по своим характеристикам были бы близки к предсказанным теоретически.

7.1 Основные принципы. Типы кодов

Кодирование с исправлением ошибок – это *метод обработки сообщений, который предназначается для повышения надежности передачи информации по цифровым каналам*. И хотя различные схемы кодирования достаточно сильно отличаются друг от друга и основаны на различном математическом аппарате, они все обладают двумя общими свойствами.

Во-первых, *использование избыточности*. Все закодированные последовательности включают дополнительные (избыточные) символы. Число символов в кодовой последовательности Y всегда превышает число символов, необходимое для однозначного представления какого-либо сообщения λ_i из алфавита.

Во-вторых, *свойство усреднения*, которое означает, что информация, составляющая кодовую последовательность X , будет перераспределяться и на избыточные символы, т.е. *избыточные символы зависят от информационных символов*.

Различают два класса корректирующих кодов – *сверточные и блочные*, различие между которыми состоит в наличии или отсутствии памяти кодера.

Кодер для блочных кодов разделяет непрерывную информационную последовательность X на блоки-сообщения длиной k символов.

*Кодер канала преобразует блоки-сообщения X в более длинные двоичные последовательности Y , которые называются *кодowymi словами* и состоят из n символов. Символы $(n-k)$, приписываемые к каждому блоку-сообщению кодером, носят название *избыточных*. Эти символы не несут дополнительной информации, и *предназначены для обнаружения (или исправления) ошибок*, возникающих в процессе передачи данных.*

Как известно, k -разрядным двоичным словом возможно представить 2^k значения из алфавита источника, которым будут соответствовать 2^k кодовых слова на выходе кодера.

*Подобное множество 2^k кодовых слов носит название **блочного кода**.*

Термин "без памяти" подразумевает, что *каждый произвольный блок из n символов будет зависеть только от соответствующего информационного блока из k символов и не будет зависеть от других блоков*.

Кодер для свёрточных кодов не предполагает разбиение информационной последовательности на независимые блоки. В некоторый момент времени кодер из текущего блока информационных символов длиной в b символов (блока-сообщения) образует блок, который состоит из v кодовых символов (кодový блок), при этом $v > b$ и кодový v -символьный блок будет зависеть от предшествующих m блоков-сообщений и b -символьного блока-сообщения, который присутствует на входе кодера в настоящий момент. В этом и заключается наличие памяти в кодере.

Блочное кодирование удобно использовать в ситуациях, когда исходные данные уже сгруппированы в некоторые блоки или массивы.

При передаче данных по радиоканалам чаще всего используется сверточное кодирование, лучше приспособленное к побитовой передаче данных. Также при равной избыточности сверточные коды обладают лучшей исправляющей способностью.

7.2. Линейные блочные коды

Для любого блочного кода с 2^k кодовыми словами длиной в n символов (за исключением кодов специальной структуры), аппарат кодирования/декодирования является достаточно сложным. В связи с этим рассмотрим только те коды, которые имеют практическую реализацию.

Одним из основных условий реализуемости блочных кодов в случае больших k является линейность.

Блочный код длиной n символов, состоящий из 2^k кодовых слов, называется линейным (n, k) -кодом при условии, что все его 2^k кодовых слов образуют k -мерное подпространство векторного пространства n -последовательностей двоичного поля $GF(2)$.

Иначе, двоичный код является линейным, если сумма по модулю 2 двух кодовых слов также является кодовым словом этого кода.

Рассмотрим некоторые основы двоичной арифметики, так как, работая с двоичными кодами, мы постоянно будем сталкиваться с ее элементами.

Поле называется множество математических объектов, с которыми можно выполнять операции складывания, вычитания, умножения и деления.

Рассмотрим простейшее поле, которое состоит из двух элементов – единицы и нуля. Операции сложения и умножения в этом случае выглядят следующим образом:

$$\begin{array}{ll} 0+0=0, & 0*0=0; \\ 0+1=1, & 0*1=0; \\ 1+0=1, & 1*0=0; \\ 1+1=0, & 1*1=1. \end{array}$$

Приведенные операции сложения и умножения называются сложением по модулю 2 и умножением по модулю 2.

При этом, что из равенства $1+1=0$ следует, что $-1=1$ и, как следствие, $1+1=1-1$, и соответственно, так как $1*1=1$, то $1:1=1$.

Алфавит из двух символов 0 и 1 одновременно со сложением и умножением по модулю 2 носит название поля из двух элементов и обозначает-

ся как $GF(2)$. К полю $GF(2)$ применяются матричные операции и все методы линейной алгебры.

При работе с линейными блочными кодами желательно, чтобы они обладали свойством *систематичности*.

Систематический код содержит *постоянную информационную часть* длиной k символов и *избыточную (проверочную)* длиной $n-k$ символов и имеет формат, изображенный на рис. 7.1.




Рис. 7.1

Блочный код, который обладает свойствами систематичности и линейности, называется *линейным блочным систематическим (n, k) -кодом*.

Линейные коды обладают следующими основными свойствами:

1. Если v_i – это кодовое слово, то: $v_i H_{(n,k)}^T = [0 \ 0 \ \dots \ 0]$.
2. Произведение некоторого кодового слова v_i' с ошибкой на $H_{(n,k)}^T$ даёт синдром S_i : $v_i' H_{(n,k)}^T = S_i$.
3. $G_{(n,k)} H_{(n,k)}^T = 0$.
4. Кодовое расстояние d_0 (n, k) -кода равно минимальному числу линейно зависимых столбцов $H_{(n,k)}$.
5. Произведение информационного слова на $G_{(n,k)}$ даёт кодовое слово.
6. Два кода называются эквивалентными, если их порождающие матрицы $G_{(n,k)}$ отличаются только перестановкой столбцов и элементарными операциями над строками.

7. Кодовое расстояние любого линейного (n, k) -кода удовлетворяет неравенству $d_0 \leq n - k + 1$ (граница Сингтона). Если выполняется строгое равенство, то данный код называется кодом с максимальным расстоянием.

8. Граница Плоткина для минимального количества контрольных разрядов: $r \geq 2d_0 + 2 - \log_2 d_0$ при $n \geq 2d_0 - 1$.

7.2.1. Код с проверкой на четность

Простейшим линейным блочным кодом является $(n, n-1)$ -код, который построен с помощью одной общей проверки на четность. Так например, кодовое слово $(4, 3)$ -кода можно записать как вектор-столбец:

$$\overline{U}^T = (m_0, m_1, m_2, m_0+m_1+m_2), \quad (7.1)$$

где m_i - символы информационной последовательности со значениями 0 и 1, суммирование которых производится по модулю 2 (**mod2**).

Основная идея проверки на четность заключается в следующем.

Допусти, что информационная последовательность источника имеет следующий вид

$$m = (1 \ 0 \ 1). \quad (7.2)$$

Тогда кодовая последовательность, соответствующая ей, будет выглядеть таким образом :

$$U = (U_0, U_1, U_2, U_3) = (1 \ 0 \ 1 \ 0), \quad (7.3)$$

где проверочный символ U_3 образуется в результате суммирования по **mod2** символов информационной последовательности m :

$$U_3 = m_0 + m_1 + m_2. \quad (7.4)$$

Необходимо отметить, что если число единиц в последовательности m является четным, то результат суммирования будет равен нулю, если нечетным — единице, т.е. проверочный символ дополняет кодовую последовательность, делая *количество единиц в ней четным*.

При передаче данных по каналам связи в принятой последовательности могут появляться ошибки. Таким образом символы принятой последователь-

ности будут отличаться от соответствующих символов передаваемой кодовой последовательности (ноль заменяется единицей и наоборот).

Если ошибки в символах равновероятны и независимы, то вероятность появления в n -позиционном коде единственной ошибки (ошибка присутствует в одном бите, а в оставшихся $n - 1$ битах ошибка отсутствует) составит

$$P_1 = n \cdot P_{ош} \cdot (1 - P_{ош})^{n-1}. \quad (7.5)$$

Вероятность появления двух ошибок, будет определяться числом возможных сочетаний ошибок по две (в двух произвольных битах ошибка присутствует, а в оставшихся $n - 2$ битах ошибки нет):

$$P_2 = C_n^2 \cdot P_{ош}^2 \cdot (1 - P_{ош})^{n-2}. \quad (7.6)$$

Аналогично можно рассмотреть появление ошибок высокой кратности.

Если предположить, что вероятность ошибки на один символ принятой последовательности $P_{ош}$ достаточно маленькая ($P_{ош} \ll 1$) (иначе передача информации бессмысленна), то вероятность выпадения l ошибок составит $P_l \cong P_{ош}^l$.

Таким образом, не трудно заметить, что наиболее вероятно появление одиночных ошибок, с меньшей вероятностью — двойных, еще меньшей трехкратных ошибок и т. д.

Поэтому, если при передаче рассматриваемого (4,3)-кода произошла одна ошибка (в любой его позиции), то общее количество единиц в принятой последовательности r будет уже нечетным.

Из этого можно сделать вывод, что *признаком отсутствия ошибки в принятой последовательности служит четность количества единиц*. Такие коды получили название *кодов с проверкой на четность*.

Правда необходимо отметить, что если в принятой последовательности r образовалось две ошибки, то общее количество единиц в ней опять станет четным и ошибка не будет обнаружена. Но, так как вероятность двойной ошибки гораздо меньше вероятности одиночной ошибки, то наиболее вероятные одиночные ошибки этим кодом обнаруживаться будут.

Воспользовавшись общей идеей проверки на четность и также проверочным уравнением (7.4) можно создать схему кодирования/декодирования для любого произвольного кода с элементарной проверкой на четность.

Схема кодирования в этом случае будет выглядеть следующим образом (рис. 7.2):




Рис. 7.2

Декодирующее устройство для кода, имеющего проверку на четность, изображено на рис. 7.3.




Рис. 7.3

Декодер, как изображено на рис. 7.3, проверяет на четность общее количество единиц в принятой последовательности и имеет на своем выходе нуль или единицу в зависимости от того, выполнялась проверка или нет.

Отметим следующее: если сложить посимвольно два кодовых слова, принадлежащих рассматриваемому (4, 3)-коду:

$$a = (a_0, a_1, a_2, a_0 + a_1 + a_2), \text{ и } b = (b_0, b_1, b_2, b_0 + b_1 + b_2), \quad (7.7)$$

то получим следующий результат

$$c = (a_0 + b_0, a_1 + b_1, a_2 + b_2, a_0 + b_0 + a_1 + b_1 + a_2 + b_2) = (c_0, c_1, c_2, c_0 + c_1 + c_2), \quad (7.8)$$

означающий, что проверочный символ в образовавшемся слове c определяется по тем же правилам, что и в его слагаемых. Таким образом, c также будет являться кодовым словом рассматриваемого кода.

Рассмотренный пример иллюстрирует еще одно важное свойство, которыми обладают линейные блочные коды — замкнутость, заключающиеся в том, что *сумма двух кодовых слов выбранного кода также является кодовым словом*.

Пример

Необходимо послать сообщение $x = 0010011110$, контрольный бит $x_{11} = 1$. По-сылаемое сообщение выглядит следующим образом: $x = 00100111101$. В результате стороннего вмешательства сообщение было искажено и принято в виде: $y = 00100001001$. $z = 1$. Таким образом, данному каналу связи доверять больше нельзя. ●

Несмотря на свою не очень высокую эффективность, коды с проверкой на четность очень широко применяются в системах хранения и передачи информации. Они ценятся своей простотой и невысокой избыточностью, так как достаточно добавления к передаваемой последовательности всего одного избыточного символа, чтобы узнать, есть ли ошибка в принятой последовательности. Однако, определить место этой ошибки и, как следствие, испра-

вить ее, пока не представляется возможным. Можно лишь продублировать передачу слова с допущенной ошибкой, тем самым ее исправив.

7.2.2. Итеративный код

Еще одна часто используемая простая схема кодирования, может быть построена следующим образом.

Предположим, что требуется передача девяти информационных символов $\mathbf{m} = (m_0, m_1, \dots, m_8)$. Расположим эти символы в виде квадратной матрицы, как представлено в табл. 7.1, и добавим к каждой строке и столбцу этой таблицы проверочный символ для проверки на четность.

Таблица 7.1

m_0	m_1	m_2	$P_1 = m_0 + m_1 + m_2$
m_3	m_4	m_5	$P_2 = m_3 + m_4 + m_5$
m_6	m_7	m_8	$P_3 = m_6 + m_7 + m_8$
$m_0 + m_3 + m_6$	$m_1 + m_4 + m_7$	$m_2 + m_5 + m_8$	$m_0 + m_0 + m_1 + m_1 + \dots + m_8 + m_8$

Таким образом, правило четности единиц будет выполняться по строкам столбцам этой таблицы.

Если в ходе передачи данных по каналу с помехами в представленной таблице произойдет одна ошибка (например, в символе m_4), то проверка на четность в соответствующих строке и столбце (в нашем примере - P_2 и P_5) не выполнится. То есть координаты ошибки будут однозначно определены номерами столбца и строки, в которых не выполнятся проверки на четность. Таким образом, рассматриваемый код, используя *различные подходы проверки на четность* (по столбцам и по строкам), способен как обнаруживать, так и исправлять ошибки (исправление ошибки при известных координатах заключается в замене символа на противоположный: ноль на единицу и наоборот).

Описанный метод кодирования получил название *итеративного*. Он оказывается достаточно полезным в случае естественного формирования

данных в виде массивов, например, в памяти, имеющей табличную структуру, и т.д. При этом размерность таблицы значения не имеет (3×3 или 20×20), но в первом случае исправлению подлежит одна ошибка на $3 \times 3 = 9$ символов, а во втором – одна на $20 \times 20 = 400$ символов.

Еще на один момент необходимо обратить внимание. Если для *обнаружения ошибки* в простом коде с проверкой на четность достаточно *добавить всего один символ* к информационной последовательности, то для *исправления однократной ошибки*, понадобилось добавить еще *семь проверочных* символов к девяти информационным.

Как видно, избыточность этого кода является достаточно большой, а исправляющая способность – сравнительно низкой. Поэтому все усилия специалистов в области создания алгоритмов помехоустойчивого кодирования всегда направлялись на поиск таких методов и кодов кодирования, которые обеспечивали бы *максимальную исправляющую способность при минимальной избыточности*.

7.2.3. Порождающая матрица линейного блочного кода

Выше мы рассмотрели два простейших корректирующих кода - код с простой проверкой на четность, который позволяет обнаруживать однократную ошибку в принятой последовательности, и блочный итеративный код, исправляющий одну ошибку при помощи цикла проверок на четность по столбцам и строкам таблицы. Но до сих пор мы не определили формальное правило для кодирования, т.е. *преобразования информационной последовательности в кодовое слово*. Как же создаются блочные коды?

Для корректирующих кодов простейшим способом их задания и описания является *табличный способ*, в соответствии с которым каждой информационной последовательности из таблицы кода назначается кодовое слово (табл. 7.2)

Таблица 7.2

m	U
-----	-----

000	0000
001	0011
010	0101
011	0110
100	1001
101	1010
110	1100
111	1111

Подобный способ описания кодов применим не только линейных кодов. Однако, при больших значениях k размер кодовой таблицы будет слишком большим, что не позволит пользоваться им на практике (например, для кода с простой проверкой на четность двухбайтового слова размер таблицы составит $\sim 2^5 * 2^{16} = 2000000$ двоичных символов).

Еще один способ определения линейных блочных кодов основан на использовании *системы проверочных уравнений*, которые задают правило преобразования символов информационной последовательности в кодовые символы. Для примера приведенного выше система проверочных уравнений выглядит следующим образом:

$$\begin{aligned}
 U_0 &= m_0, \\
 U_1 &= m_1, \\
 U_2 &= m_2, \\
 U_3 &= m_0 + m_1 + m_2.
 \end{aligned}
 \tag{7.9}$$

Но самым наглядным и удобным способом для описания линейных блочных кодов являются *порождающие матрицы*, представляющие собой компактную форму задания системы проверочных уравнений:

$$\underline{G} = \left| \begin{array}{cccc|cccc} 1 & 0 & 0 & \dots & 0 & P_{00} & P_{01} & \dots & P_{0, n-k-1} \\ 0 & 1 & 0 & \dots & 0 & P_{10} & P_{11} & \dots & P_{1, n-k-1} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \end{array} \right|. \tag{7.10}$$

$$\left| \begin{array}{c} 0 \ 0 \ 0 \ \dots \ 1 \\ \text{единичная} \\ \text{матрица } \mathbf{I} \\ k \times k \end{array} \right| \left| \begin{array}{c} P_{k-1,0} \ P_{k-1,1} \ \dots \ P_{k-1,n-k-1} \\ \text{матрица } \mathbf{P} \\ k \times (n-k) \end{array} \right|$$

Определение. *Линейный блочный систематический (n,k) -код полностью определяется матрицей $\underline{\mathbf{G}}$ размером $k * n$ с двоичными матричными элементами. При этом каждое кодовое слово является линейной комбинацией строк матрицы $\underline{\mathbf{G}}$, а каждая линейная комбинация строк $\underline{\mathbf{G}}$ - кодовым словом.*

Рассмотрим блок-сообщение $\mathbf{m} = (m_0, m_1, \dots, m_{k-1})$, которое необходимо закодировать с использованием рассматриваемого кода.

Соответствующим блоку-сообщению кодовым словом $\mathbf{U}$ будет

$$\mathbf{U} = \mathbf{m} \cdot \mathbf{G}. \quad (7.11)$$

Учитывая структуру матрицы $\underline{\mathbf{G}}$ символы кодового слова $\mathbf{U}$ представляются в виде:

$$\text{для } i = 0, 1, 2, \dots, k-1$$

$$U_i = m_i; \quad (7.12)$$

$$\text{для } i = k, k+1, \dots, n$$

$$U_i = m_0 \cdot P_{0j} + m_1 \cdot P_{1j} + m_2 \cdot P_{2j} + \dots + m_{k-1} \cdot P_{k-1,j}. \quad (7.13)$$

Иначе, k крайних левых символов кодового слова совпадают с символами кодируемой информационной последовательности, а остальные $(n - k)$ символов являются линейными комбинациями символов информационной последовательности.

Такой код получил название *линейного блочного систематического (n,k) -кода с обобщенными проверками на четность*, а задающая его матрица $\underline{\mathbf{G}}$ – *порождающей матрицей кода*.

Рассмотрим в качестве примера известный $(7,4)$ -код Хемминга, который является классическим простейшим кодом с исправлением ошибок.

Рассмотрим сообщение $\mathbf{m} = (m_0, m_1, m_2, m_3)$, которое нужно закодировать.

Порождающая матрица $\underline{G}$ для (7, 4)-кода Хемминга имеет вид

$$\underline{G}_{(7,4)} = \begin{vmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 0 & 1 \end{vmatrix}. \quad (7.14)$$

В этом случае символы соответствующего кодового слова определяются так :

$$U = m \cdot \underline{G} = (m_0 m_1 m_2 m_3) \begin{vmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 0 & 1 \end{vmatrix} =$$

$$= (m_0, m_1, m_2, m_3, m_0 + m_2 + m_3, m_0 + m_1 + m_2, m_1 + m_2 + m_3), \quad (7.15)$$

или

$$\begin{aligned} U_0 &= m_0, \\ U_1 &= m_1, \\ U_2 &= m_2, \\ U_3 &= m_3, \\ U_4 &= m_0 + m_2 + m_3, \\ U_5 &= m_0 + m_1 + m_2, \\ U_6 &= m_1 + m_2 + m_3. \end{aligned} \quad (7.16)$$

Например, если $m = (1\ 0\ 1\ 1)$, то соответствующее кодовое слово примет вид $U = (1\ 0\ 1\ 1\ 1\ 0\ 0)$. Или: если $m = (1\ 0\ 0\ 0)$, то $U = (1\ 0\ 0\ 0\ 1\ 1\ 0)$.

Интересно, что опираясь на приведенное выше определение, строки матрицы $\underline{G}$ будут являться кодовыми словами рассматриваемого кода, а оставшиеся кодовые слова – линейными комбинациями строк порождающей матрицы.

Пользуясь порождающей матрицей $\underline{G}_{(7,4)}$ (7.15) или рассмотренной системой проверочных уравнений (7.16) достаточно легко может быть реализована схема кодирования для (7,4)-кода Хемминга (рис. 7.4).

Кодер в этом случае работает так же, как и при простой проверке на четность, однако теперь он выполняет не одну общую проверку, а несколько частичных, формируя, таким образом, несколько проверочных символов.




Рис. 7.4

7.2.4. Проверочная матрица

Линейный систематический блочный код также может быть определен с использованием так называемой проверочной матрицы $\underline{H}$, обладающей следующим свойством:

- если некоторая последовательность $\underline{U}$ является кодовым словом, то

$$\underline{U} * \underline{H}^T = 0. \quad (7.17)$$

Иначе, проверочная матрица $\underline{H}$ ортогональна любой кодовой последовательности данного кода.

Проверочная матрица будет иметь размерность $(n-k) * n$ и структуру :

$$\left| \begin{array}{cccc|cccc} P_{00} & P_{10} & \dots & P_{k-1,0} & 1 & 0 & 0 & \dots & 0 \end{array} \right|$$

$$\underline{H} = \left[\begin{array}{cccc|ccccc} P_{01} & P_{11} & \dots & P_{k-1,1} & 0 & 1 & 0 & \dots & 0 \\ P_{22} & P_{12} & \dots & P_{k-1,2} & 0 & 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ P_{0,n-k-1} & P_{1,n-k-1} & \dots & P_{k-1,n-k-1} & 0 & 0 & 0 & \dots & 1 \end{array} \right], \quad (7.18)$$

P^T
 $I_{(n-k) \times (n-k)}^1$

где $\underline{P}^T$ - транспонированная подматрица $\underline{P}$ из порождающей матрицы $\underline{G}$;

$\underline{I}_{(n-k) \times (n-k)}^1$ - единичная матрица соответствующего размера.

Как видно, единичная и проверочная подматрицы в $\underline{G}$ и $\underline{H}$ поменялись местами. Кроме этого, изменился их размер.

Для рассматриваемого (7,4)-кода Хемминга проверочная матрица $\underline{H}$ будет иметь вид

$$H_{(7,4)} = \left[\begin{array}{cccc|ccc} 1 & 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 & 1 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 & 1 \end{array} \right] \quad (7.19)$$

По проверочной матрице легко определить, будет ли *являться приня-
тая последовательность кодовым словом данного кода.*

Например, рассмотрим последовательность символов $c = (1011001)$. Для нее

$$c * H^T = (1011001) \left[\begin{array}{cccc|ccc} 1 & 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 & 1 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 & 1 \end{array} \right]^T = (1 \ 1 \ 0) \neq \underline{0}.$$

Таким образом, можно сделать вывод, что последовательность $c = (1011001)$ не является кодовым словом данного кода.

Или другой пример. Пусть есть последовательность $d = (0010111)$, то-
гда

$$\mathbf{d} \cdot \underline{\mathbf{H}}^T = (0010111) \left[\begin{array}{cccc|ccc} 1 & 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 & 1 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 & 1 \end{array} \right]^T = (0 \ 0 \ 0) \neq \underline{0},$$

т.е. двоичная последовательность $\mathbf{d}$ принадлежит коду с проверочной матрицей $\underline{\mathbf{H}}$.

Пример

Дана порождающая матрица: $G_{(5,3)} = \left[\begin{array}{ccc|cc} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{array} \right]$.

Кодирование задается отображениями: $000 \rightarrow 00000$, $001 \rightarrow 00110$, $010 \rightarrow 01011$, $011 \rightarrow 01101$, $100 \rightarrow 10001$, $101 \rightarrow 10111$, $110 \rightarrow 11010$, $111 \rightarrow 11100$.

Например:

$$[0 \ 1 \ 1] \cdot G_{(5,3)} = \left[0 \ 1 \ 1 \ \underbrace{0 \cdot 0 \oplus 1 \cdot 1 \oplus 1 \cdot 1}_0 \ \underbrace{0 \cdot 1 \oplus 1 \cdot 1 \oplus 1 \cdot 0}_1 \right] = [0 \ 1 \ 1 \ 0 \ 1]$$

Проверочная матрица: $H_{(5,3)} = \left[\begin{array}{ccc|cc} 0 & 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \end{array} \right]$.

Проверяем свойство 1: $[0 \ 1 \ 1 \ 0 \ 1] \cdot H_{(5,3)}^T = [0 \ 0]$.

Проверяем свойство 4: линейно зависимые столбцы в $H_{(5,3)}$ – это 1-ый и 5-ый (например). Значит, $d_0 = 2$. Посмотрим на (*): видим, что минимальное кодовое расстояние кода действительно равно 2.

Свойство 7 (граница Сингтона): $2 \leq 5 - 3 + 1$. ●

8. Основы криптографии

8.1. Основные термины и понятия криптологии

Наука криптология, занимающаяся проблемами защиты информации за счет ее преобразования, состоит из двух разделов: криптография и криптоанализ.

Криптография, как область практической и научной деятельности, до 70-ых годов прошлого века была связана с разработкой, применением и различного рода шифросистем. Сегодня эта область человеческой деятельности связана с разработкой, анализом и применением систем криптографической защиты информации.

Основными функциями криптографических систем являются обеспечение аутентичности и конфиденциальности различных сторон информационного взаимодействия.

В качестве источников угроз при постановке и решении различных криптографических задач выступают *преднамеренные* действия *недобросовестного* участника или противника информационного взаимодействия, но не случайное изменение информации, вызванное помехами, отказами и т.п.

Конфиденциальность заключается в защищенности информации от возможности ознакомления с ее содержанием лицами, не имеющими права доступа к ней.

Аутентификация – это проверка, подтверждение и установление подлинности различных составляющих информационного взаимодействия: сеанса связи, сторон (идентификация), содержания (имитозащита), источника (установление авторства) передаваемых сообщений, времени взаимодействия и пр. Проблема аутентификации значительно обостряется при недоверии друг к другу сторон информационного взаимодействия, т.е. в случае, когда источником угрозы помимо третьей стороны (противника), выступает сторона, к которой направлено информационное взаимодействие.

Криптоанализ – наука о способах и методах анализа криптографических отображений информации с целью ее раскрытия.

Основные составляющие части криптографии показаны на рис.8.1.




Рис. 8.1. Схема взаимодействия составляющих криптографии

Криптосистема – система, предназначенная для обеспечения безопасности защищенной сети с использованием криптографических средств. Подсистемами криптосистемы являются ключевая система, обеспечивающая функционирование других подсистем: шифрования, имитозащиты, цифровой подписи, идентификации и др.

Основанием для выбора и построения криптосистемы является условие, обеспечивающее ее криптографическую стойкость. Тип ключевой системы является классификационным признаком деления криптосистем на симметричные и асимметричные.

Встречается два понятия криптографических средств. С одной стороны, это средства и методы, служащие для обеспечения безопасности информации, которые используют криптографические преобразования информации (другими словами – преобразование информации с применением какого-либо криптографического алгоритма в зависимости от назначения криптографической системы). С другой стороны, под криптографическими средствами в более узком смысле понимают средства в виде документов, программ, различного рода технических устройств служащих для реализации функций криптографических систем.

Рассмотрим пример. Пусть некий отправитель желает отправить письмо получателю, но так, чтобы при перехвате это сообщение никто не смог бы

прочсть. Это передаваемое сообщение носит название открытого текста, преобразование этого сообщения – шифрованием, обратный процесс преобразования сообщения в открытый текст – дешифровки, а зашифрованное сообщение – шифротекста.




Рис. 8.2. Процесс шифрования/дешифрования

Введем обозначения:

- M (*message*) – открытый текст (например, текстовый файл, поток битов и т.п.).
- C (*ciphertext*) – шифротекст, $size(C) \stackrel{\geq}{\underset{\leq}{=}} size(M)$.
- E – функция шифрования, $E(M) = C$.
- D – функция дешифрования, $D(C) = M$.

При этом необходимо выполнение: $D(E(M)) = M$.

Криптографический алгоритм (или шифр) есть некоторые математические функции, которые используются для шифрования/дешифрования.

В том случае, если в основе безопасности алгоритма лежит задача сохранения этого алгоритма в тайне, такой алгоритм называется ограниченным. Подобные алгоритмы совсем не соответствуют современным стандартам криптографии. Более того, в случае исключения одного из участников из крупной группы пользователей потребуется изменение алгоритма шифрования.

Современные средства криптографии эту проблему решают при помощи ключа k . Этот ключ может принимать любое значение, выбираемое из

большого множества K . Все множество возможных ключей называется пространством ключей.

Таким образом, криптосистема есть не что иное, как все возможные открытые тексты, шифротексты, алгоритмы и ключи.

Если в процессе шифрования и дешифрования применяется один и тот же ключ, то имеют дело с симметричным шифрованием. Конечно же этот ключ обязан храниться в секрете, отсюда другое название подобных систем – системы с секретным ключом.

В случае несимметричного шифрования (иначе алгоритм с открытым ключом) различают два типа ключей: k_1 – открытый ключ, который доступен всем участникам информационного обмена и k_2 – закрытый ключ, доступный только отправителю сообщения; $E_{k_1}(M) = C$ и $D_{k_2}(C) = M$. Определить ключ k_2 дешифрования по k_1 практически невозможно.

Безопасность алгоритмов подобных типов полностью основана на ключах, т.е. эти алгоритмы шифрования возможно опубликовать и проанализировать.

Достоинством симметричных алгоритмов является их высокая скорость работы, небольшие размеры этих ключей и более высокие гарантии обеспечения криптостойкости.

В отличие от симметричных, в несимметричных криптосистемах применяются более удобные протоколы.

Криптографический протокол – это заданная последовательность действий, которые выполняются для решения криптографической задачи. Отличием алгоритма от протокола является то, что для реализации протокола требуется взаимодействие нескольких сторон протокола.

К одной из наиболее важных криптографических задач относится задача распределения ключей. Классификация протоколов по видам представлена на рис. 8.3.



Рис. 8.3. Виды протоколов обмена ключами

8.2. Основные понятия криптоанализа

Попытка криптоанализа носит название вскрытия. В XIX веке Д. А. Керкхофс впервые сформулировал *основное предположение криптоанализа*, заключающееся в том, что безопасность полной мере определяется ключом и, что криптоаналитик имеет полное описание алгоритма шифрования, а также его реализацию.

Криптоаналитическое вскрытие бывает нескольких типов:

1. Вскрытие только с использованием шифротекста (криптоаналитик имеет несколько зашифрованных с использованием одного и того же алгоритма сообщений).

Дано: $C_1 = E_k(M_1), \dots, C_i = E_k(M_i)$.

Требуется найти: или $M_1 \div M_i, k$; или алгоритм, получения M_{i+1} из $C_{i+1} = E_k(M_{i+1})$.

2. Вскрытие с использованием открытого текста.

Дано: $M_1, C_1 = E_k(M_1), \dots, M_i, C_i = E_k(M_i)$.

Требуется найти: или k , или алгоритм получения M_{i+1} из $C_{i+1} = E_k(M_{i+1})$.

3. Вскрытие с использованием выбранного открытого текста.

Дано: $M_1, C_1 = E_k(M_1), \dots, M_i, C_i = E_k(M_i)$, при этом $M_1 \div M_i$ можно выбирать любыми.

Требуется найти: или k , или алгоритм получения M_{i+1} из $C_{i+1} = E_k(M_{i+1})$.

4. Адаптивное вскрытие с использованием открытого текста (отличие данного типа от п. 2 состоит в том, что в данном случае криптоаналитик может выбрать меньший по объему блок, затем следующий, используя при этом результаты шифрования предыдущего блока и т. д.).

5. Вскрытие с использованием выбранного шифротекста (применяется, как правило, к алгоритмам с открытым ключом).

Дано: $C_1, M_1 = D_k(C_1), \dots, C_i, M_i = D_k(C_i)$, в этом случае $C_1 \div C_i$ могут выбираться любыми.

Требуется найти: k

6. Вскрытие с использованием выбранного ключа (криптоаналитик имеет некоторую информацию о связи между различными ключами).

7. Бандитский криптоанализ (шантаж, угрозы и др. Это наиболее быстрый путь взлома криптосистемы).

В зависимости от сложности взлома алгоритма разные алгоритмы дают и различную степень безопасности. Рассматривают следующее деление на категории, предложенное Ларсом Кнудсеном:

1. Полное вскрытие: требуется найти k такой, что $D_k(C) = M$.

2. Глобальная дедукция: находится альтернативный алгоритм эквивалентный $D_k(C)$ без знания k .

3. Локальная дедукция: находится M для перехваченного C .

4. Информационная дедукция: находится некоторая информация о k или M (информация о форме открытого текста, несколько бит ключа и т. д.).

Безусловно безопасным называется такой алгоритм шифрования, в котором независимо от объема шифротекстов, имеющих у криптоаналитика, недостаточно данных для получения открытого текста.

8.3. Шеноновские модели криптографии

Общая схема симметричной криптосистемы представлена на рис. 8.4.




Рис. 8.4. Схема симметричной криптосистемы

Рассмотри математические модели, характерные для элементарных криптосистем:

1. Подстановка: пусть имеется открытое сообщение $[x_1, \dots, x_n]$ в алфавите A и система отображений $\Phi = \{\varphi_1, \dots, \varphi_n\}$ символов из алфавита A в алфавит шифрованного текста B . Тогда зашифрованный текст представит в виде: $Y = [\varphi_1(x_1), \dots, \varphi_n(x_n)]$.

Если φ_i есть биективное отображение, тогда система Φ будет являться подстановочным шифром замены, в противном случае – многозначным шифром замены.

2. Перестановка: пусть имеется открытое сообщение $[x_1, \dots, x_n]$; перестановка имеет вид $\Psi = \{\psi_1, \dots, \psi_n\}$. Тогда зашифрованный текст будет выглядеть следующим образом: $Y = [x_{\psi_1}, \dots, x_{\psi_n}]$.

Недостатками представленной модели являются:

- часто встречаемые символы в X и Y будут совпадать;
- ограничения по размеру ключа, которые приводят к его многократному применению;

Для усиления криптостойкости этого криптопреобразования целесообразно использовать композицию из нескольких перестановок, отличающиеся длинами блоков.

3. Шифр Виженера и его модификация: пусть имеется некоторое открытое сообщение $[x_1, \dots, x_n]$; тогда шифрованное сообщение будет получаться путем преобразования: $y_t = (x_t + k^\tau) \bmod |X|$, в котором $t = (i - 1) \cdot T + \tau$, $i = 1, 2, \dots$; $\tau = \overline{1, T}$, где T – длина блока. Ключ k есть фиксированный набор символов, принадлежащих алфавиту открытого сообщения.

Тогда обратное преобразование будет иметь вид: $x_t = (y_t - k^\tau + |X|) \bmod |X|$.

Частными случаями будут являться: шифры Цезаря, Бофора.

4. Криптопреобразование Вернама (или поточный шифр): является частным случаем шифра Виженера, в котором $T = n$. Ключ k здесь будет называться гаммой, одноразовым блокнотом или бегущей строкой.

5. Биграммная подстановка: данная подстановка использует принцип простой подстановки, однако вместо подстановки типа «один сим-

вол – один символ», происходит одновременная подстановка типа « m СИМВОЛОВ – m СИМВОЛОВ».

Идеально стойким называется шифр, в котором невозможно однозначно определить открытый текст при наличии известного зашифрованного текста произвольной большой длины (любой совершенно стойкий шифр будет являться идеально стойким).

Абсолютно стойким будет называться шифр, в котором длина однократно используемого ключа, являющегося частью случайной двоичной последовательности, описываемой равномерным законом распределения, и длина исходного сообщения равны. В таких шифрах ключ сразу же уничтожается после использования, поэтому, даже обладая неограниченными вычислительными и временными ресурсами, криптоаналитику вскрыть такой шифр практически не представляется возможным.

Как видно, необходимыми и достаточными признаками абсолютной стойкости шифра будут являться:

- равенство длин открытого текста и ключа;
- полная случайность ключа;
- одноразовое использование ключа.

К. Шеннон теоретически доказал существование криптосистемы, которая обладает совершенной безопасностью (т.е. шифр, кроме длины, не дает никакой другой информации об открытом сообщении). Такое возможно в случае, если число возможных ключей будет таким же большим, что и число возможных сообщений (другими словами, ключ не должен дважды использоваться и быть короче открытого сообщения).

Основными показателями криптостойкости являются

1. Количество всех возможных ключей;

2. Среднее время, затрачиваемое на криптоанализ;
3. Количество и качество (или достоверность) всех криптограмм, которые были перехвачены;
4. Шифросистема обладает высокой криптографической стойкостью, когда выражается экспоненциально через длину ключа;
5. Количество материала, необходимого для анализа при вскрытии шифра (к примеру, полный перебор ключей криптосистемы);
6. Стоимость процесса дешифрирования системы (например, разработка новой вычислительной системы).

Для всех современных криптографических систем защиты информации можно сформулировать следующие общие требования:

- только имея ключ зашифрованное сообщение может быть прочитано;
- число операций, требуемых для расшифровывания информации, используя перебор всех возможных ключей, должно характеризоваться строгой нижней оценкой и превосходить возможности современных компьютерных систем (даже с учетом всех возможностей распараллеливания и сетевых вычислений);
- количество операций, требуемых для определения уже использованного ключа шифрования по некоторому фрагменту шифрованного сообщения и соответствующего ему открытого текста, должно быть не менее общего количества возможных ключей;
- несущественное изменение ключа должно в результате приводить к значительному изменению зашифрованного сообщения (даже если ключ один и тот же);
- знание алгоритма шифрования не может влиять на надежность защиты;
- структурные элементы составляющие алгоритм шифрования не должны меняться;
- длина шифрованного текста и длина исходного текста должны быть равны;

- биты, дополнительно вводимые в сообщение в ходе шифрования, должны быть надежно и полностью скрыты в зашифрованном тексте;
- не должно быть легко и просто устанавливаемых зависимостей между ключами, которые последовательно используются в процессе шифрования;
- алгоритм шифрования должен допускать и программную и аппаратную реализацию;
- изменение длины ключа не должно приводить к качественному ухудшению выбранного алгоритма шифрования;
- любой ключ из всего множества возможных ключей должен обеспечивать надежную защиту всей информации.

Для дальнейшего рассмотрения систем шифрования будем считать, что необходимые математические основы криптологии были получены в рамках курсов «Высшая математика».

8.4 Примеры систем шифрования

Система шифрования RSA

Система шифрования RSA является шифрованием с открытым ключом. В основе алгоритма RSA лежит предположение, что поиск больших простых чисел вычислительно не представляет сложности, однако практически невозможно разложить большое простое число на произведение двух таких чисел.

В основе системы лежит следующая степенная функция: $f(x) = x^e \bmod n$.

Здесь блок x открытого текста, является целым числом из диапазона $[0, n-1]$ и преобразуется с помощью вычисления: $y = x^e \bmod n$ в блок шифротекста из этого же диапазона. Пара (e, n) носит название открытого ключа и применяется при шифровании сообщения. Число $n = p \cdot q$, где p, q – различные простые случайные числа. Эти числа генерируются одной из сторон, участвующих в информационном обмене.

В случае расшифровывания применяется функция $\tilde{f}(x) = x^d \bmod n$: $x = y^d \bmod n$. Здесь пара (d, n) носит название закрытого ключа и используется при дешифровании.

Согласованность этих преобразований обосновывает теорема Эйлера. (пусть $n > 1$, $\text{НОД}(z, n) = 1$; тогда: $z^{\varphi(n)} \equiv 1 \pmod{n}$).

Чтобы воспользоваться теоремой Эйлера, в RSA используют такие числа e, d , для которых: $ed \equiv 1 \pmod{\varphi(n)}$, $\varphi(n) = (p-1)(q-1)$. Тогда если e известно, то d – есть решение сравнения первой степени. Или иначе, проверив $\text{НОД}(e, \varphi(n)) = 1$, с использованием расширенного алгоритма Евклида можно найти d, t : $ed + t\varphi(n) = 1$.

Проверим работоспособность формулы дешифрования:

$$\begin{aligned} x &= y^d \bmod n = (x^e \bmod n)^d \bmod n = [(x^e \bmod n) \cdot \dots \cdot (x^e \bmod n)] \bmod n = \\ &= x^{ed} \bmod n = x^{1-t\varphi(n)} \bmod n = x \cdot x^{-t\varphi(n)} \bmod n = \\ &= [x \bmod n \cdot (x^{\varphi(n)} \bmod n)^{-t}] \bmod n \stackrel{\text{Т.Эйлера}}{=} [x \bmod n \cdot 1^{-t}] \bmod n = x \end{aligned}$$

В основе криптостойкости системы шифрования RSA лежит то, что, имея открытый ключ (e, n) , криптоаналитик может найти d :

- а) зная функции Эйлера $\varphi(n)$. Эта задача – есть задача разложения (или факторизации) n на простые множители. Однако, нахождение функции Эйлера по определению задача вычислительно труднореализуемая. Даже используя самый эффективный алгоритм факторизации (например, решето числового поля), число n , длиной в 50 десятичных разрядов, может быть разложено приблизительно за 10^{10} операций (суперкомпьютеры), а если 800 десятичных разрядов – примерно за 10^{51} операций (не раскладывается вообще в настоящее время).
- б) Либо найти $\sqrt[n]{y}$. (задача дискретного логарифма – см. пункт 4.2.3.5).

Пример

Для упрощения расчетов используем небольшие числа.

Будем использовать таблицу ASCII кодов минус 64 для перевода сообщений в числа.

Предположим, что абонент A сгенерировал два простых числа: $p = 3, q = 11 \Rightarrow n = 33, \varphi(n) = 20$. Находим $e: \text{НОД}(e, n) = 1, 1 < e < \varphi(n)$, например $e = 7$.

Пара $(7, 33)$ публикуется как открытая.

Находим далее $d: 7d \equiv 1 \pmod{\varphi(n)} \Rightarrow d = 3$.

Пара $(3, 33)$ при этом держится абонентом A в тайне.

Пусть теперь абонент B хочет послать секретное сообщение: «СAB». В нем $A \rightarrow 1, B \rightarrow 2, C \rightarrow 3$.

Зашифруем: $C_1 = 3^7 \bmod 33 = 9, C_2 = 1^7 \bmod 33 = 1, C_3 = 2^7 \bmod 33 = 29$.

Попробуем теперь дешифровать: $C'_1 = 9^3 \bmod 33 = 15$ (не получается!).

Абоненту A посылают: «[A]».

Абонент A переводит сообщение в числовое представление и дешифрует его:

$M_1 = 9^3 \bmod 33 = 3, M_2 = 1^3 \bmod 33 = 1, M_3 = 29^3 \bmod 33 = 2$. Получается сообщение: «СAB».●

Система шифрования Диффи-Хеллмана

В основе данного алгоритма, также относящегося к алгоритмам секретного обмена ключом между абонентами, лежит сложность вычисления дискретного логарифма.

Рассмотрим простейший пример создания двумя абонентами общего ключа.

Абоненты A, B выбирают большое простое число n и g – первообразный корень по модулю n . Образуется пара (n, g) , объявляемая открытой.

Абонент A выбирает случайным образом большое секретное число $x < n$ и отправляет его абоненту B : $X = g^x \bmod n$.

Абонент B также выбирает случайное большое секретное число $y < n$ и отправляет его абоненту A : $Y = g^y \bmod n$.

Абонент A вычисляет ключ: $k_A = Y^x \bmod n$.

Абонент B вычисляет ключ: $k_B = X^y \bmod n$.

Проверим, совпадают ли ключи у абонентов:

$$\begin{aligned} k_A &= Y^x \bmod n = (g^y \bmod n)^x \bmod n = g^{xy} \bmod n = (g^x \bmod n)^y \bmod n = \\ &= X^y \bmod n = k_B \end{aligned}$$

Таким образом, далее можно работать полученным ключом в симметричной криптосистеме.

Для сокращения размера возможных окончательных значений ключа, очень важно чтобы функция модульного возведения в степень была максимально взаимнооднозначной. В случае, если n является простым числом, то всегда существует такое g , для которого $g^x \bmod n$ будет принимать каждое из значений из диапазона $\overline{0, n-1}$, когда x принимает значения из этого же интервала. Таким образом, g выбирают как первообразный корень по модулю n .

Пример

$$n = 7, \varphi(n) = 6 = 2 \cdot 3.$$

В примере пункта 4.2.3.4 мы выяснили, что первообразные корни по модулю $6 : 3$ и 5 . Возьмем, например $g = 3$. $(7, 3)$ – открыта.

Абонент A сгенерировал случайное число $x = 2 < n$, и вычислив $X = 3^2 \bmod 7 = 2$, послал абоненту B .

Абонент B сгенерировал случайное число $y = 5 < n$, и вычислив $Y = 3^5 \bmod 7 = 5$, послал абоненту A .

Абонент A принял $Y = 5$ и вычислил ключ: $k_A = 5^2 \bmod 7 = 4$.

Абонент B принял $X = 2$ и вычислил ключ: $k_B = 2^5 \bmod 7 = 4$.

Заключение

Рассмотренный в данном пособии материал, прежде всего, конечно, был ориентирован на рассмотрение методов экономного кодирования (сжатия) информации. Причем, именно методов сжатия информации без потерь, потому что методы сжатия с потерями были достаточно подробно рассмотрены в учебном пособии «Мультимедийные технологии» в силу того, что их применение прежде всего ориентировано на большие объемы информации (видео, музыка, графика, анимация).

Рассмотренные методы сжатия, наряду с рассмотренными алгоритмами криптографического шифрования очень удобны для реализации лабораторного практикума, для отработки навыков эффективного программирования.

Список литературы

1. Харин Ю.С., Берник В.И., Матвеев Г.В., Агиевич С.В. Математические и компьютерные основы криптологии: Учеб. пособие. / Ю.С. Харин, В.И. Берник, Г.В. Матвеев, С.В. Агиевич. – Минск: ООО Новое знание, 2003.– 382 с.
2. Шнайер Б., Прикладная криптография. Протоколы, алгоритмы и исходные тексты на языке С, 2-ое издание. / Брюс Шнайер. Пер. с англ. – М.: "Триумф", 2002. – 816 с.
3. Фомичев В. М. Дискретная математика и криптология. / В. М. Фомичев.– М.: Диалог-МИФИ, 2003.– 400 с.
4. Василенко О. Н. Теоретико-числовые алгоритмы в криптографии: Монография. / О. Н. Василенко. – М.: Московский центр непрерывного математического образования, 2003.–328 с.
5. Шульгин В.И. Основы теории передачи информации. Ч. 1. Экономное кодирование): Учеб. пособие. /В.И. Шульгин. – Харьков: Нац. аэрокосм. ун-т “ХАИ”, 2003. – 102 с.
6. Лидовский В.В. Теория информации: Учеб. пособие. / В.В. Лидовский. – М.: Компания Спутник+, 2004. – 111 с.
7. Мао В.Современная криптография. Теория и практика. – Пер. с англ. – М.:Издательский дом ”Вильямс”, 2005. – 768с.
8. Гульяева Т.А. Основы теории информации и криптографии. Конспект лекций/ Новосиб. гос. техн. ун-т – Изд-во НГТУ , 2006 – 27 с.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1. Основные понятия. Система передачи информации.....	4
1.1. Система передачи информации	6
2. Источники сообщений. Дискретизация. Квантование	13
2.1. Теорема дискретизации	16
2.2. Квантование сообщений.....	17
3. Задачи и постулаты теории информации. Количественная оценка информации	20
3.1 Постулаты теории информации.....	21
3.2 Количественная оценка информации.....	22
4. Вероятностно-статистические модели сообщений и их свойства	27
4.1 Источники дискретных сообщений и их вероятностные модели	27
4.2 Собственная информация.....	29
4.3. Взаимная информация	31
6. Основные принципы кодирования	40
6.1. Принципы кодирования.....	42
6.2. Алгоритмы сжатия без потерь.	47
7. Помехоустойчивое кодирование	59
7.1 Основные принципы. Типы кодов.....	60
7.2. Линейные блочные коды	62
8. Основы криптографии	75
8.1. Основные термины и понятия криптологии.....	76
8.2. Основные понятия криптоанализа.....	80
8.3. Шеноновские модели криптографии	82
Заключение	90
Список литературы	91